Raio-X Comercial · Documentação do projeto

Projeto final da trilha IA Aplicada (SENAI/TCS) · Equipe: Marcos (dados), Eduardo (IA e gestão), Náthally (produto e métricas), Miguel (tela e infraestrutura) · Repositório: `MiguelGrispan/trabalho-tcs` (GitHub)

Versão: rascunho 2 (para revisão do grupo), sex 06/11/2026 · Final prevista: seg 09/11/2026 · Entrega: seg 16/11/2026, 48 h antes da banca, prevista para qua 18/11/2026 **[PENDENTE: data e horário da banca a confirmar com o professor]**

> **Versão para revisão.** O BPMN, a arquitetura e a EDA já estão no documento. Ainda faltam, marcados com **[PENDENTE]**: o ROI (nenhuma medição manual de tempo foi feita até 06/11), o texto final de ética da Náthally e respostas do professor. A lista completa está no fim (Apêndice B) e sai da versão final.

O que este documento cobre

seção	o que o professor pede	fonte
1. O problema e o produto	contexto do tema e do objetivo	`requisitos_projeto.MD`, Documentação
2. Etapas desenvolvidas	"um documento ... explicando as etapas desenvolvidas durante o processo"	`requisitos_projeto.MD`, Documentação
3. Dados: limpeza e indicadores	Python e Pandas para limpeza, nulos e estruturação; SQL	`guia_projeto_final.pdf` §2
4. Processo (BPMN 2.0)	"Fluxograma BPMN 2.0 do processo"	guia §6; `requisitos_projeto.MD`, Documentação
5. Arquitetura e infraestrutura	arquitetura; "Infraestrutura automatizada com Terraform"	guia §2 e §6; `requisitos_projeto.MD`, Aplicação
6. Justificativa técnica	"Justificativa técnica das escolhas de modelos/arquiteturas (ex.: RAG vs Fine-tuning)"	guia §6 e §7
7. Ética, governança e segurança	"análise de ética e segurança"; viabilidade, limitações, viés, confiabilidade e uso responsável	guia §2, §5 e §6
8. Métricas	métricas de sucesso	guia §3 (bloco 5)
9. Como usamos IA para programar	agentic coding; arquivos de prompts do vibecoding	guia §2; `requisitos_projeto.MD`, Aplicação
10. Lições aprendidas	"lições aprendidas do trabalho em equipe"	guia §3 (bloco 6)

Os dois arquivos do professor estão no repositório, sem mudança, em `docs/professor/`.

---

1. O problema e o produto

Quem usa: o executivo de contas B2B, que vende produtos ou serviços para empresas grandes.

A dor: antes da primeira reunião com uma companhia, ele precisa entender o tamanho dela, se cresce, se a margem está apertada e se está endividada. Hoje ele abre o site de relações com investidores (RI), procura os números à mão, tenta comparar com o setor e pensa em perguntas. Leva tempo, cada vendedor faz de um jeito e a comparação com empresas parecidas quase nunca acontece.

O que o Raio-X entrega. O vendedor escolhe uma companhia aberta da CVM, diz o que vende e o objetivo da reunião, e recebe em segundos:

- 6 indicadores das demonstrações financeiras entregues à CVM (DFP), cada um com a conta de onde veio;
- a posição de cada indicador contra o grupo de empresas de perfil parecido (K-means);
- 3 a 5 perguntas para a reunião, ligadas ao produto, e o que os números não mostram (lacunas);
- 5 empresas parecidas para prospectar (vizinhos mais próximos).

A regra de ouro. O texto é escrito por um LLM (Gemini, via LangChain), mas **o LLM nunca escreve números**. Ele usa marcadores como `{margem_ebit}`; um validador remove qualquer trecho com número fora de marcador; o código troca os marcadores pelos valores calculados da tabela. Número inventado num material de vendas é o pior erro possível: os valores mostrados vêm sempre da tabela, e o validador barra algarismos e as quantidades por extenso que ele conhece (o que ele não pega está na seção 7.2).

O que já foi medido e o que não foi. A ferramenta gera um raio-x em **2,15 s em média** (10 casos, seção 8), contando a montagem dos indicadores, a chamada ao Gemini e a validação; o custo estimado da API é **US$ 0,001185 por raio-x**. Não há, até 06/11, uma medição comparável do tempo de montar o mesmo raio-x à mão (pelo site de RI). Sem ela, este documento **não afirma ganho de tempo nem ROI**: os 2,15 s não incluem o tempo do vendedor para escolher a empresa, ler e conferir o texto.

[PENDENTE: ROI · NA3, Náthally] *Cronometrar 1 raio-x montado à mão (mesma empresa, mesmos 6 indicadores, pelo site de RI) e 1 com a ferramenta, os dois contando o tempo de ler e conferir; escrever a conta do ganho em 3 linhas.*

---

2. Etapas desenvolvidas

O projeto durou 4 semanas (19/10 a 16/11/2026). O detalhe de cada passo está nos pull requests do repositório (`gh pr list --state all`) e o resumo diário em `docs/HISTORICO.md`.

Semana 1 (19 a 25/10): cada um no seu canto

- **Repositório criado** (19/10) e primeiras entregas separadas: produto e regras do texto (Náthally), carga e limpeza da DFP (Marcos, numa branch própria) e a primeira versão do Raio-X com IA, segmentação, checador de dados, tela e testes (Eduardo, PR #1).
- A **regra de ouro** nasce no PR #1 (21/10), junto com o `REGRAS-IA.md`, as regras do time para o uso de IA.

Semana 2 (26/10 a 01/11): juntar tudo e fazer funcionar

- **Fundação** (PR #2, 26/10): uma pasta por dono e o código do Marcos trazido para a estrutura comum.
- **Integração contínua** (27/10): testes automáticos em todo PR, versões fixas (Python 3.14) e os primeiros 3 raio-x com dados reais (595 empresas). O teste revelou um problema: o K-means pôs 567 das 595 empresas num grupo só.
- **Segmentação consertada** (PR #9, 28/10): receita mínima de R$ 10 mi, extremos cortados e menor grupo com 5% ou mais. A silhueta caiu de 0,77 para 0,30 (0,286 com os dados de 05/11), mas os grupos passaram a ser úteis (seção 6).
- **Prompt da Náthally no código** (PR #11, 29/10): o Gemini lê o arquivo de regras dela, sem cópia. **Avaliação com 10 casos reais** (PR #20): 0 trechos removidos pelo validador (seção 8).
- **PostgreSQL** (PRs #21 e #22, 29 e 30/10): o professor fixou o PostgreSQL em aula (SQLite não vale); o CI passou a subir um banco só para os testes, para nenhum teste de banco ser pulado.
- **Docker** (PR #24, 30/10): `docker compose up` sobe a tela e o PostgreSQL juntos.
- **Terraform** (PR #29, 31/10): `terraform apply` sobe a mesma infraestrutura; o `destroy` mantém o banco e os dados.

- **Travas para a IA de programação** (PR #30, 31/10): regras que custam caro quebrar viraram bloqueios automáticos (seção 9).

Semana 3 (02 a 08/11): fechar o código e escrever

- **Justificativa técnica** (PR #31, 02/11) e **tela ligada ao banco** (PR #36, 02/11): a tela busca as empresas no PostgreSQL, grava cada consulta e, se o Gemini falhar, cai sozinha no modo sem IA.
- **Demo ponta a ponta** (03/11): Vale, Embraer e Ambev sem IA e WEG com o Gemini (US$ 0,0011), pelo `docker compose` e pelo Terraform, com tudo gravado no banco. Tag `v0.1-demo`.
- **Correção do ano fiscal** (PR #46, 03/11): a Camil fecha o exercício em fevereiro, e o sistema mostrava o exercício anterior. O "ano" de cada número passou a ser o do exercício. 5 empresas conferidas contra o RI, com diferença de 0,00% (seção 8).
- **Tela mais clara e mais segura** (PR #47, 04/11): aviso curto quando a IA falha, a tela só diz "escrito por IA" quando o Gemini respondeu e só abre no próprio computador. A carga da CVM refeita com a correção do ano fiscal deu 595 empresas e a Camil com o valor do RI.
- **Decisões de 04/11:** a demo da banca roda no Mac do Eduardo, o único conferido com o compose, o Terraform e o Gemini, e os vídeos são gravados nele; este documento passa a ser escrito em markdown e convertido em PDF.
- **BPMN 2.0** (Marcos, PR #52, 04/11; ajustado no #65, 06/11) e **EDA** (Marcos, PR #54, 04/11): a EDA achou um erro de escala que a limpeza não pegava (NTS com crescimento de +107.154%), consertado no PR #59 (05/11).
- **Diagrama de arquitetura** (Miguel, PR #55, 05/11) e **legenda da tela** dizendo de onde vem cada número (Miguel, PR #61, 05/11).
- **Avaliação refeita** (Eduardo, PR #58, 05/11): os 10 casos com os dados corrigidos e o K-means treinado de novo (seção 6.2).
- **Consertos antes do congelamento** (Eduardo, PR #63, 05/11): o validador passou a barrar quantidade sem algarismo ("dobrou", "um quarto"), a tela acha empresas carregadas depois de aberta e as travas funcionam no Windows. **Limpeza** do código que ninguém usava (Marcos, PR #64, 05/11).
- Código congelado e tag `v1.0` na sex 06/11; vídeo final gravado na `v1.0` no sáb 07/11. **[PENDENTE: a tag `v1.0` ainda não existe em 06/11, manhã; confirmar as datas reais no fim da semana]**

Semana 4 (09 a 16/11): entregar e ensaiar

- Documento, deck e vídeo da demo prontos em qua 11/11; ensaios cronometrados; entrega em seg 16/11; banca prevista para qua 18/11 (a confirmar).

As decisões que mais mudaram o projeto

data	decisão	por quê
21/10	o LLM nunca escreve números; usa marcadores	número inventado num material de vendas é o pior erro possível
26/10	cada pasta tem um dono	quatro pessoas no mesmo arquivo geravam conflito
28/10	K-means só com receita a partir de R$ 10 mi, extremos cortados, menor grupo com 5% ou mais	sem isso, um grupo tinha 567 das 595 empresas
28/10	"empresas parecidas" = mesmo perfil financeiro, não o mesmo setor	é o que o modelo mede
29/10	banco PostgreSQL	regra do professor: SQLite não vale
30/10	Terraform obrigatório	`requisitos_projeto.MD`, Aplicação: "Infraestrutura automatizada com Terraform"
30/10	o Gemini desiste em até uns 30 s (15 s por tentativa, 2 tentativas)	sem limite, a API travada deixava a tela girando, sem chegar ao plano B

data	decisão	por quê
31/10	a chave do Gemini não passa pelo Terraform	variável do Terraform fica em texto puro no `terraform.tfstate`
02/11	sem RAG vetorial, sem fine-tuning, sem memória e sem agente	seção 6
02/11	a aplicação é o Streamlit, em 2 contêineres (tela + banco)	resposta do professor: "um contêiner para ele e a aplicação e um para o SQL"
03/11	o "ano" de cada número é o do exercício, e não o do arquivo da CVM	a Camil aparecia com o exercício anterior
05/11	não treinar o K-means de novo antes da banca; os 10 casos no mesmo grupo viram limite declarado (issue #60)	mudar o modelo a 1 dia do congelamento arriscaria a demo; o limite está explicado na seção 6.2

---

3. Dados: limpeza e indicadores

A fonte

Dados abertos da CVM, em CSV: o cadastro das companhias abertas (`cad_cia_aberta.csv`: código, nome, situação e setor) e os arquivos anuais da DFP (`dfp_cia_aberta_AAAA.zip`). Da DFP usamos a DRE (resultado), o BPA (ativo) e o BPP (passivo e patrimônio), consolidados e individuais. São baixados os exercícios de 2023 a 2025, mais o arquivo de 2026, onde está o exercício 2025 de quem fecha o ano fora de dezembro (`scripts/carregar_dfp.py`).

Regras de limpeza, na ordem

As regras 1 a 7 estão no código com o mesmo número, em `scripts/carregar_dfp.py` (regra 1) e `raiox/limpeza.py` (as outras).

1. **Ler** com `sep=";"`, `encoding="latin-1"`, `decimal=","` e `CD_CONTA` como texto. Lido como número, o código de conta `3.10` viraria `3.1`. (`ler_demo()`, `scripts/carregar_dfp.py`)
2. **Só o exercício do ano** (`ORDEM_EXERC == "ÚLTIMO"`): a CVM manda também o ano anterior, e cada conta apareceria duas vezes.
3. **Só a maior versão** de cada empresa: reapresentações substituem a entrega original. Se a mesma versão traz dois períodos, fica o fim de exercício mais recente. (`limpar_demo()`)
4. **Escala:** `ESCALA_MOEDA = MIL` vira × 1.000. Além disso, o código acha empresas que declaram "unidade" mas mandam milhares: a receita cai cerca de 1.000 vezes de um ano para o outro e, multiplicada por 1.000, fica parecida com a do ano anterior. Esses anos são corrigidos e o script avisa. (`encontrar_escala_errada()` e `corrigir_escala()`)
5. **Consolidado primeiro:** sem demonstração consolidada, usa a individual e anota a origem (`con` ou `ind`). (`preferir_consolidado()`)
6. **Só empresas com receita de venda positiva** no último ano: bancos e seguradoras usam a conta 3.01 para outras receitas (ex.: "Receitas da Intermediação Financeira") e ficam de fora. (`filtrar_empresas_com_receita()`)
7. **Nulos: não inventar.** Valor que falta fica vazio, e a tela mostra "sem dado". Se a mesma conta aparece duas vezes com valores diferentes, o valor fica vazio em vez de escolher um (`resolver_conflitos()`). Divisão por zero ou por valor negativo deixa o indicador vazio em vez de infinito (`montar_indicadores()`, `scripts/indicadores.py`).

O ano do exercício (PR #46). A CVM arquiva cada DFP pelo ano em que o exercício termina, mas nem toda empresa fecha em dezembro. A Camil fecha em fevereiro: o "2025" dela vai de mar/2025 a fev/2026. O ano de cada número passou a ser aquele em que cai a maior parte dos meses do exercício (`ano_do_exercicio()`,

`raiox/limpeza.py`). Mudaram as 9 empresas que fecham fora de dezembro; a receita da Camil foi de R$ 12,26 bi (o exercício anterior) para R$ 11,12 bi, o valor do RI.

Os 6 indicadores

Uma linha por empresa, no último exercício (`montar_indicadores()`, `scripts/indicadores.py`; formato no contrato C2, `contratos.md`).

indicador	fórmula	contas da DFP	o que diz ao vendedor
Receita líquida	valor da conta, último ano	DRE 3.01	tamanho da empresa
Crescimento em dois anos	receita do último ano ÷ receita de 2 anos antes – 1	DRE 3.01	está expandindo ou encolhendo
Margem EBIT	resultado antes do resultado financeiro e dos tributos ÷ receita	DRE 3.05 ÷ 3.01	pressão de custo na operação
Margem líquida	lucro do período ÷ receita	DRE 3.11 ÷ 3.01	o que sobra depois de juros e impostos
Ativo total	valor da conta, último ano	BPA 1	tamanho pelo que a empresa tem
Endividamento	1 – patrimônio líquido ÷ ativo total	BPP 2.03 e BPA 1	quanto depende de terceiros

Onde os dados ficam (SQL)

O PostgreSQL 17 guarda as tabelas `contas` (uma linha por empresa × ano × demonstração × conta, com índice único que recusa conta repetida), `empresas` (do cadastro), `indicadores` (os 6 indicadores) e `consultas` (cada raio-x pedido na tela: empresa, produto, objetivo, tempo e custo). A busca da tela usa `ILIKE` e devolve só companhias ativas e com indicadores (`raiox/dados.py`). Se o banco estiver desligado, a conexão desiste em 5 s e a tela mostra o que fazer, em vez de travar (`raiox/banco.py`).

Resultado da carga (Marcos, 03/11): 384.591 linhas de contas e 595 empresas com os 6 indicadores, em 1 min 48 s. A base usada neste documento (carga de 05/11, depois do PR #59) tem os mesmos totais: 384.591 linhas e 595 empresas.

Auditoria dos dados

`raiox/checagem.py` aplica regras de sanidade (ex.: margem acima de 100%, receita que muda demais) e **só aponta**: quem decide é uma pessoa. Com os dados de 05/11: nenhum "erro" e 179 "atenção" em 98 empresas.

Análise exploratória (EDA)

O notebook `notebooks/eda.ipynb` (Marcos, PR #54) olha os dados antes de usá-los. Cada gráfico gerou uma decisão do projeto.

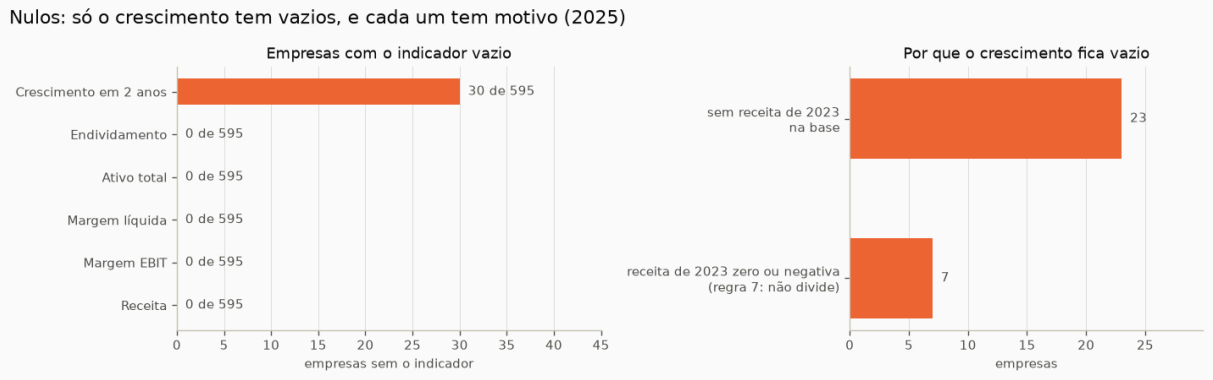


Figura 1. Nulos. Todas as empresas têm as 5 contas do último ano; o único indicador com vazios é o crescimento (falta a DFP de 2 anos antes ou a receita daquele ano era zero). Decisão: o vazio continua vazio até a tela ("sem dado"); só o K-means usa a mediana.

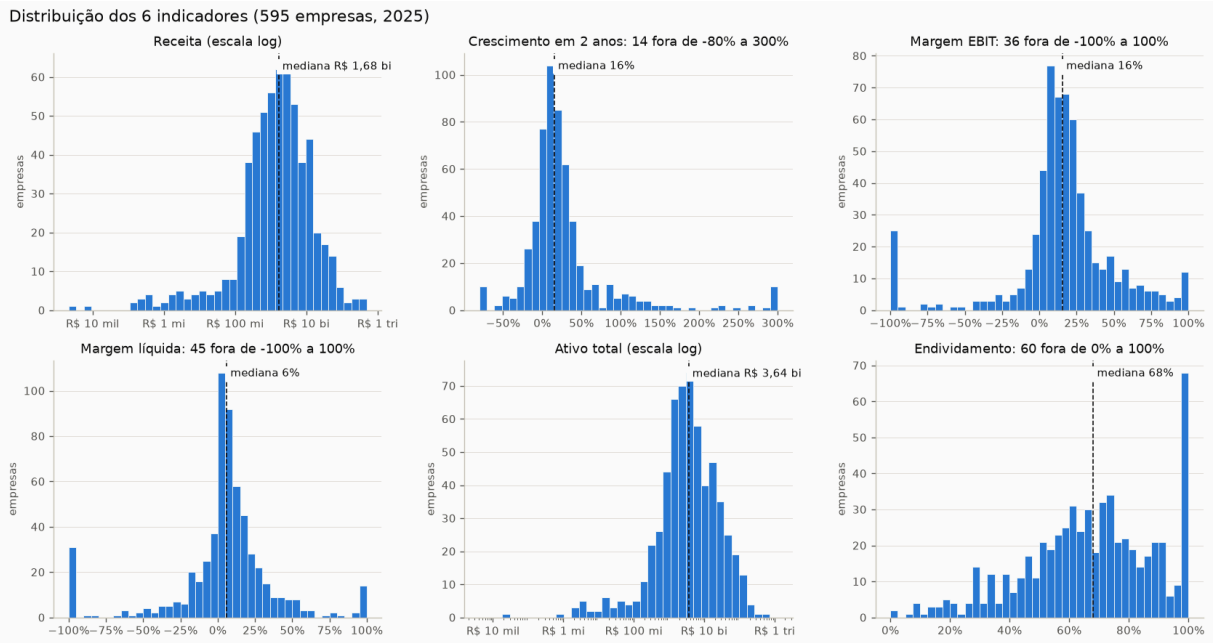


Figura 2. Distribuições. Receita e ativo só têm forma de sino na escala log, e poucas gigantes puxam a média. Decisão: comparar pela mediana do grupo, e o K-means usa o log da receita.

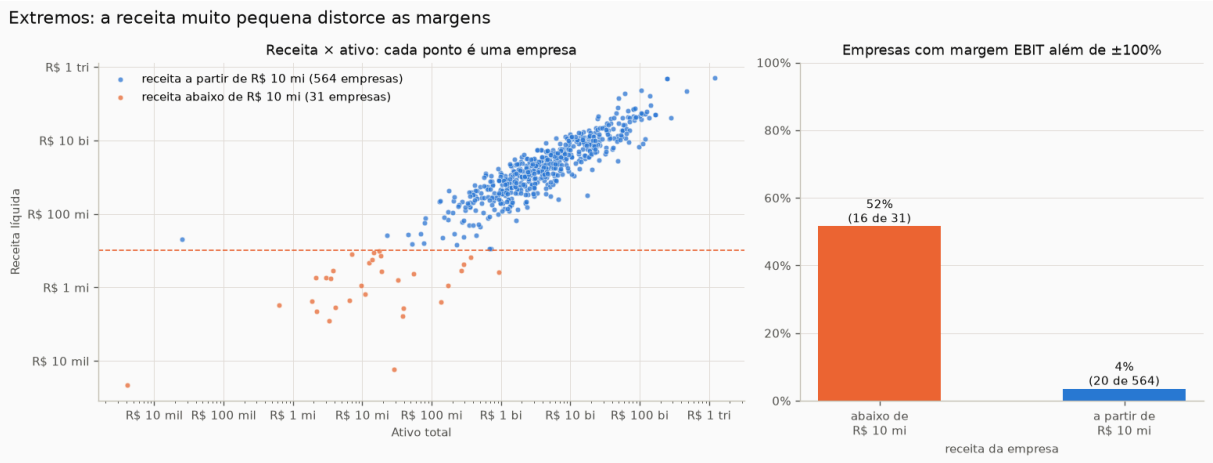


Figura 3. Extremos. Abaixo do corte de R$ 10 mi de receita estão holdings e securitizadoras, com margens sem sentido. Decisão: o K-means aprende só a partir do corte; os extremos não são apagados, são marcados para conferir na fonte.

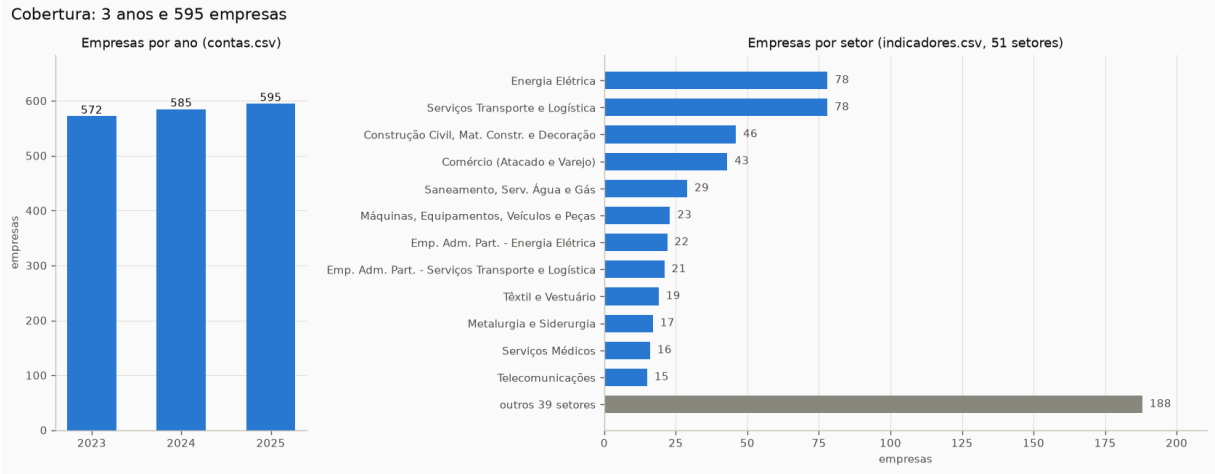


Figura 4. Cobertura. Os 3 anos têm quase o mesmo número de empresas, mas os setores são desiguais. Decisão: grupos por perfil financeiro, e não por setor; o lado ruim está na seção 7.3.

---

4. Processo de negócio (BPMN 2.0)

O diagrama (Marcos, PRs #52 e #65; arquivo editável `docs/bpmn/raio-x-comercial.bpmn`, feito no bpmn.io) mostra o processo de negócio com o Raio-X. A piscina **Raio-X Comercial** tem as raias **Vendedor** e **Aplicação Raio-X** (tela Streamlit e pacote `raiox`); o **Google Gemini** é uma piscina separada, porque é um serviço de fora, chamado pelo LangChain.

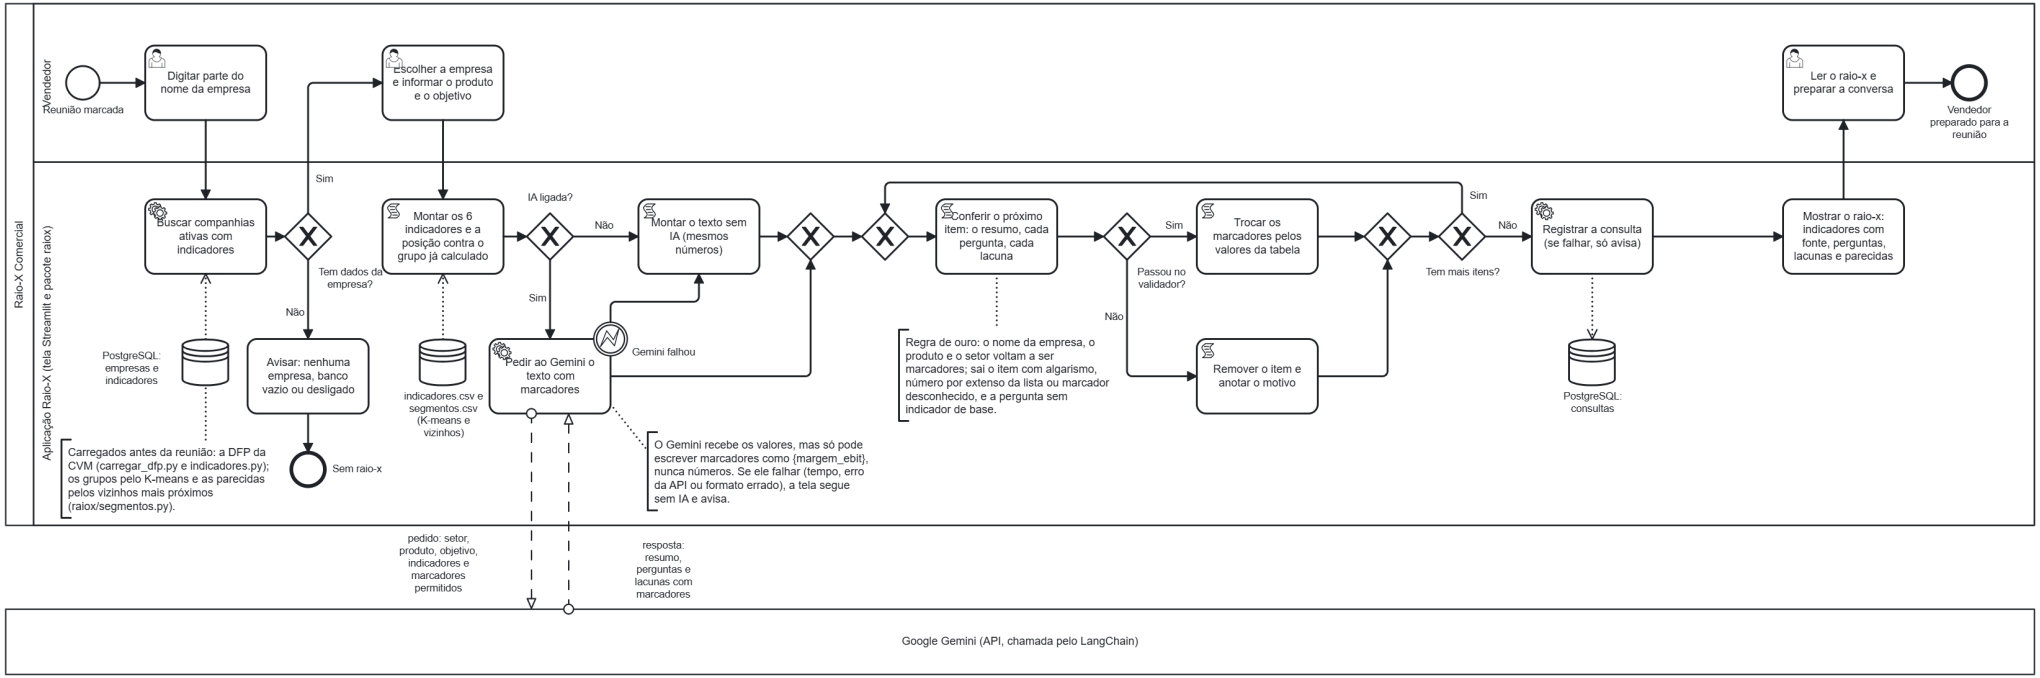


Figura 5. BPMN 2.0 do processo, da reunião marcada ao vendedor preparado. Os dados da CVM, os grupos do K-means e as parecidas são carregados antes da reunião (anotação à esquerda).

O caminho, na ordem do diagrama:

1. o vendedor digita parte do nome; a aplicação busca companhias ativas com indicadores no PostgreSQL;
2. decisão **"Tem dados da empresa?"**: se não, avisa (nenhuma empresa, banco vazio ou desligado) e o processo acaba sem raio-x;
3. o vendedor escolhe a empresa e informa o produto e o objetivo; a aplicação monta os 6 indicadores e a posição contra o grupo, já calculados (`indicadores.csv` e `segmentos.csv`);
4. decisão **"IA ligada?"**: se sim, pede ao Gemini o texto com marcadores; se não, ou se o Gemini falhar (evento de erro: tempo, erro da API ou formato errado), monta o texto sem IA, com os mesmos números;
5. para cada item (resumo, cada pergunta, cada lacuna), decisão **"Passou no validador?"**: se sim, troca os marcadores pelos valores da tabela; se não, remove o item e anota o motivo;
6. registra a consulta no PostgreSQL (se falhar, só avisa) e mostra o raio-x com fonte, perguntas, lacunas e parecidas;
7. o vendedor lê o raio-x e prepara a conversa: a revisão humana fica no fim do processo.

---

5. Arquitetura e infraestrutura

Os componentes

O diagrama completo é a Figura 6, logo abaixo.

- **Preparação** (roda uma vez; refaz quando sai DFP nova): `scripts/carregar_dfp.py` baixa e limpa a DFP da CVM e grava as tabelas `contas` e `empresas`; `scripts/indicadores.py` calcula os 6 indicadores (tabela `indicadores` e `data/indicadores.csv`); `raiox/segmentos.py` treina o K-means e acha as parecidas (`data/segmentos.csv`).
- **Consulta** (a cada uso, alguns segundos): a tela (`app/streamlit_app.py`) busca a empresa no PostgreSQL (`raiox/dados.py`), pede o raio-x a `raiox/ia.py` (números e posição pelo código, texto pelo Gemini só com marcadores, validador) e grava a consulta na tabela `consultas`. Sem IA ou com a API fora do ar, o texto é montado por modelo fixo.
- **De onde vem cada coisa:** a busca e o registro das consultas usam o PostgreSQL; os números do raio-x vêm da `data/indicadores.csv`, gerada pelo mesmo script que grava a tabela `indicadores` (a tela diz isso desde o PR #61).

Os formatos entre as partes (C1 a C4) estão no `contratos.md`: cada um trabalhou contra dados falsos no formato combinado (`falsos/`) até o colega entregar.

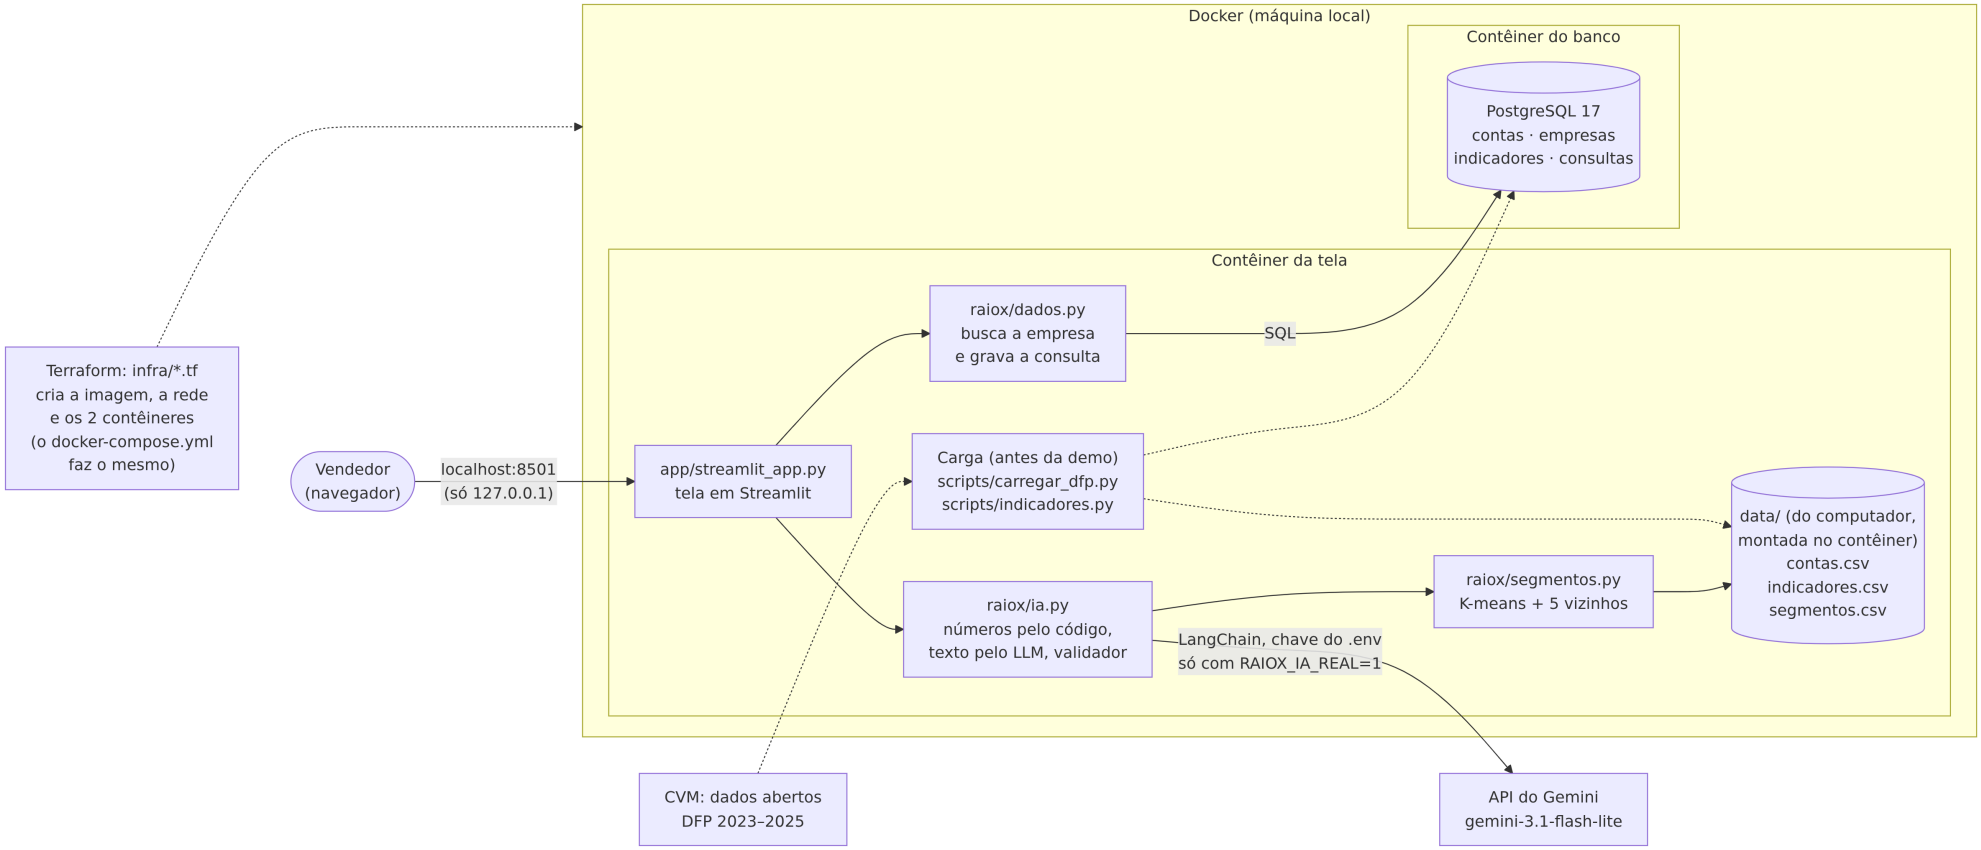


Figura 6. Arquitetura (Miguel, PR #55; o mesmo diagrama está em texto Mermaid na seção "Arquitetura" do `README.md`). O Terraform cria a imagem, a rede e os 2 contêineres no Docker local; o vendedor abre a tela só em `127.0.0.1:8501`.

Dois contêineres, dois caminhos para subir

A aplicação roda em **2 contêineres**, como o professor orientou: um com a tela e a aplicação (Streamlit + `raiox/`) e outro com o PostgreSQL. O Streamlit faz o papel de frontend (a tela) e o código de `raiox/` o de backend.

	`docker compose`	Terraform (obrigatório)
arquivo	`docker-compose.yml`	`infra/*.tf`, com o provider Docker (`kreuzwerker/docker`)
sobe	`docker compose up -d --build`	`terraform apply`
derruba	`docker compose down`	`terraform destroy` (o banco e a `data/` continuam)
conferido	Linux (Miguel, 30/10) e Mac (Eduardo, 03/11)	Linux (Miguel, 31/10) e Mac (Eduardo, 03/11): 2º `plan` sem mudanças

O Terraform roda localmente, no Docker do computador (`requisitos_projeto.MD`, Aplicação: "podendo rodar localmente ou na nuvem"). O volume do banco fica fora do Terraform, para o `destroy` não apagar os dados carregados. O CI confere o Terraform (`terraform fmt` e `terraform validate`) em todo PR que mexe em `infra/`.

Tecnologias

parte	tecnologia
linguagem	Python 3.14, versões fixas no `requirements.txt`
dados	Pandas 3.0, NumPy 2.5; dados abertos da CVM
gráficos e EDA	Matplotlib 3.11, Jupyter
banco	PostgreSQL 17, SQLAlchemy 2.1, psycopg 3.3
machine learning	scikit-learn 1.9 (KMeans, NearestNeighbors, StandardScaler)
IA generativa	Gemini `gemini-3.1-flash-lite` por API, LangChain, saída estruturada com Pydantic
tela	Streamlit 1.66
infraestrutura	Docker, Docker Compose, Terraform 1.17
testes e CI	pytest 9.1, GitHub Actions com um PostgreSQL só para os testes

---

6. Justificativa técnica

6.1 O problema decide a arquitetura

O vendedor precisa de **números certos** e de **texto útil**. Cada parte do sistema faz o que faz melhor:

quem	faz	por quê
código (Pandas)	calcula todos os números a partir da DFP	cálculo é determinístico e auditável: cada número tem conta e ano
ML (scikit-learn)	acha o grupo de empresas parecidas e as 5 mais próximas	não há rótulo de "empresa parecida": é aprendizado não supervisionado
LLM (Gemini)	escreve o texto com marcadores, nunca o número	escrever é o que o LLM faz bem; copiar e arredondar número é onde ele erra
validador (código)	remove o trecho com número fora de marcador e troca os marcadores pelos valores	é a regra de ouro

6.2 Machine learning: K-means + vizinhos mais próximos

O ML faz **duas coisas diferentes**, com dois algoritmos:

saída na tela	de onde vem	para que serve
referência de grupo (a mediana do grupo em cada indicador e a posição "acima", "abaixo" ou "em linha")	**K-means**: a empresa cai num dos 4 grupos, e o código calcula a mediana de cada indicador entre as empresas do grupo (`montar()`, `raiox/ia.py`)	dizer se a margem, o crescimento ou o endividamento estão bons **para empresas de perfil parecido**
5 empresas parecidas para prospectar	**vizinhos mais próximos** (`NearestNeighbors`), no mesmo espaço das 5 variáveis, sem olhar o grupo	achar as empresas individualmente mais próximas, mesmo que o grupo seja grande

- **Não supervisionado** porque não existe uma coluna "grupo certo" para treinar: o K-means descobre os grupos sozinho.
- **5 variáveis:** log da receita, crescimento em dois anos, margem EBIT, margem líquida e endividamento. O log porque a receita vai de milhões a centenas de bilhões; sem ele, só o tamanho decidiria o grupo.
- **Preparo:** extremos cortados nos percentis 5 e 95, nulos preenchidos com a mediana (só para o modelo; a tela mostra o valor real ou "sem dado") e `StandardScaler`, para todas as variáveis ficarem na mesma régua.
- **Treino só com receita a partir de R$ 10 mi:** abaixo disso estão 31 empresas, 52% delas com margem EBIT acima de 100% ou abaixo de −100% (holdings e empresas sem operação); acima, 564 empresas e 4% (`scripts/avaliar_corte_receita.py`, 03/11). As empresas menores recebem o grupo mais próximo, sem participar do treino.
- **Escolha do k:** testa k de 3 a 8 e fica com a maior silhueta, **mas só entre os k em que o menor grupo tem pelo menos 5% das empresas** (`escolher_k()`, `raiox/segmentos.py`).
- **5 parecidas:** `NearestNeighbors` com 6 vizinhos no mesmo espaço padronizado, porque o 1º vizinho é a própria empresa.

Resultado na base da entrega (carga de 05/11, depois das correções dos PRs #46 e #59; conferido de novo em 06/11): **k = 4, silhueta 0,286**, grupos de 60, 310, 88 e 106 empresas no treino (564 empresas). Com as 595, contando as que só recebem o grupo mais próximo: 66, 312, 103 e 114. Silhueta dos outros k: 0,265 (k = 3), 0,250 (5), 0,253 (6), 0,217 (7) e 0,219 (8).

Por que a silhueta de 0,77 enganava. Antes da regra dos 5%, a silhueta era 0,77 e parecia ótima, mas o modelo só separava 9 empresas extremas e juntava todas as outras num grupo só: 567 das 595. Com a regra, a silhueta cai para 0,30 (0,286 com os dados de 05/11) e os grupos passam a servir para comparar. Preferimos grupos úteis a um número bonito.

O limite: os 10 casos de avaliação caem no mesmo grupo (issue #60). As 10 empresas da avaliação (seção 8) estão todas no grupo de 312 empresas, que vai de R$ 284 mil a R$ 497,5 bi de receita, com mediana de R$ 3,6 bi. As 10 têm receita de R$ 11,1 bi (Camil) a R$ 497,5 bi (Petrobras) e ficam entre os 27% maiores do grupo em receita. Por isso, nos 10 raio-x, **receita e ativo saem "acima do grupo" em todos os casos**: a referência de grupo não distingue porte entre empresas grandes, e a Petrobras é comparada com a mesma mediana da Camil. O motivo é o desenho do modelo: o tamanho (log da receita) é só 1 das 5 variáveis, e os grupos se separam mais pelo perfil. Os outros 3 grupos são os que fogem do comum (crescimento alto, prejuízo com dívida alta, margem muito alta); este é o grupo do "perfil comum" (medianas: crescimento de 15%, margem EBIT de 13%, endividamento de 66%), onde cabem de empresas pequenas a gigantes. O que atenua: as **5 parecidas** vêm dos vizinhos, não do grupo, e para esses casos são empresas grandes (ex.: as da Petrobras são CPFL, TIM, Motiva, Neoenergia e Suzano). A comparação de **margens e endividamento** contra o grupo continua útil; a de **tamanho**, não. Decidimos não treinar de novo antes da banca (seção 2) e declarar o limite (seção 7.3).

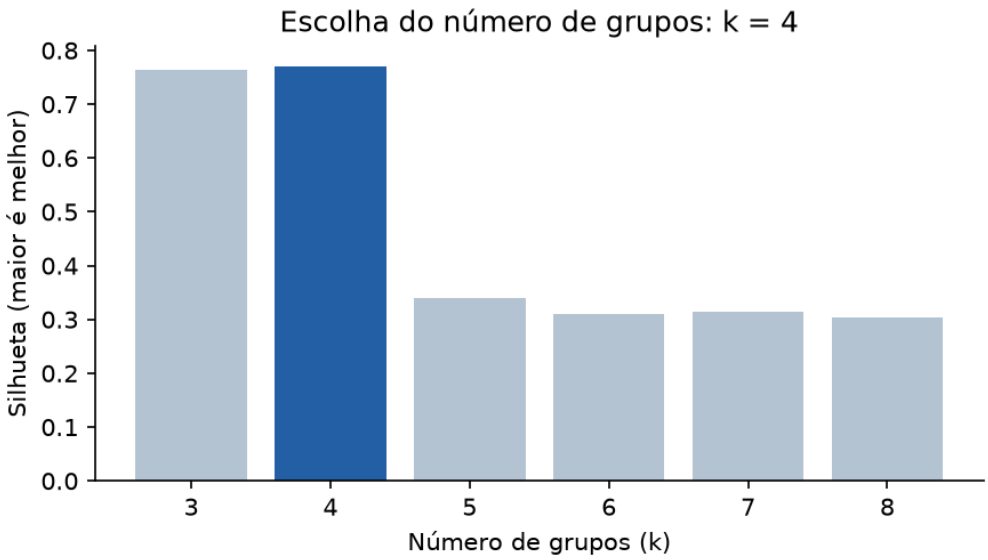


Figura 7. Silhueta por k antes da regra dos 5% (27/10): 0,77 em k = 4, com quase todas as empresas num grupo só.

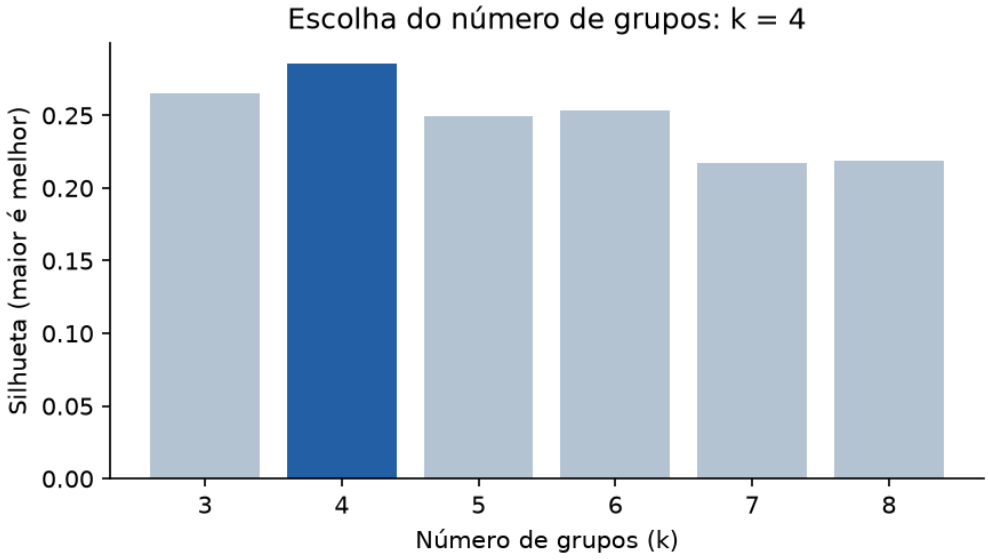


Figura 8. Silhueta por k depois da regra dos 5% (dados de 05/11): 0,286 em k = 4.

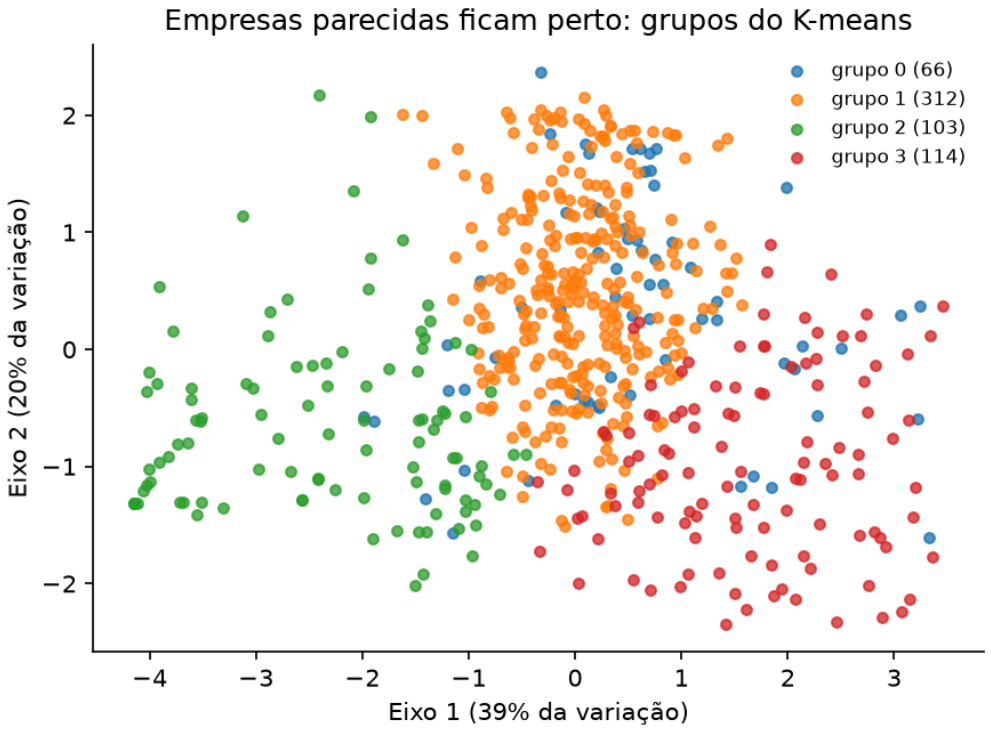


Figura 9. Os 4 grupos projetados em 2 dimensões (PCA), com os dados de 05/11 (a legenda conta as 595 empresas). As 5 variáveis viram 2 eixos só para desenhar; o modelo usa as 5.

6.3 IA generativa: por que nem RAG vetorial nem fine-tuning

A base de dados da IA é a tabela de indicadores calculada da DFP da CVM. O código busca a linha exata da empresa pelo código CVM (`montar()`, `raiox/ia.py`) e entrega ao Gemini, para cada indicador, o nome, o valor da empresa, a mediana do grupo (já formatados, ex.: "R$ 12,3 bi") e a posição ("acima", "abaixo" ou "em linha"), calculada por código. O Gemini **lê** esses valores para entender a empresa, mas **só pode escrever os marcadores**. É geração aumentada por recuperação, com a recuperação **estruturada** (pela chave da empresa), e não semântica (por embeddings).

opção	o que seria	por que não usamos
RAG vetorial	quebrar documentos em pedaços, gerar embeddings e buscar os trechos mais parecidos com a pergunta	os dados são números em tabela, não texto. Busca por semelhança pode trazer a empresa ou o ano errado; busca por chave traz sempre a linha certa. Exigiria também um banco vetorial a mais
Fine-tuning	treinar o modelo com exemplos de raio-x bons	não temos centenas de exemplos rotulados; custa mais; os dados mudam todo ano; e treinar **não impede** o modelo de errar número, que é o risco principal
O que usamos	prompt + saída estruturada (Pydantic) + validador	barato (US$ 0,001185 por raio-x, estimado pelos tokens), reproduzível e conferível

Se a tabela de indicadores conta como a "base de dados de conhecimento" que o `requisitos_projeto.MD` pede (Integração com IA de terceiro) é uma pergunta ao professor, ainda sem resposta. O projeto também segue o caminho "Treinamento de Machine Learning" (seção 6.2), e o `requisitos_projeto.MD` pede uma das duas abordagens. **[PENDENTE: resposta do professor à pergunta 3]**

Quando o RAG passaria a valer: se o raio-x tivesse de ler texto livre, como o release de resultados ou as notas explicativas da DFP.

6.4 Chain, memória e agentes no LangChain

- **Uma chain de dois passos** (`_chain()`, `raiox/ia.py`): `ChatPromptTemplate` (as regras como mensagem de sistema + o pedido) → `ChatGoogleGenerativeAI(...).with_structured_output(RaioX)`.
- **Saída estruturada:** a resposta volta no formato `RaioX` (resumo, perguntas e lacunas), garantido pelo Pydantic.
- **O prompt de sistema** é o arquivo de regras da Náthally (`avaliacao/regras_prompt.md`), lido sem cópia, mais 3 notas do código. Assim, o que a dona das regras escreve chega inteiro ao modelo.
- **Modelo pequeno** (`gemini-3.1-flash-lite`, `temperature=0.2`): a tarefa é escrever 3 frases e algumas perguntas; um modelo pequeno basta, custa menos e varia pouco entre uma chamada e outra.
- **Limites:** 15 s por tentativa e 2 tentativas. Se a API travar, o erro chega em uns 30 s e a tela não fica girando.
- **Sem memória, de propósito:** cada raio-x é independente. Memória de conversa só traria o risco de misturar dados de uma empresa na outra.
- **Sem agente, de propósito:** o caminho é sempre o mesmo (buscar → calcular → escrever → validar). Não há decisão para um agente tomar, e um pipeline fixo é mais previsível e mais fácil de testar.
- **Plano B sem IA:** `texto_sem_ia()` monta o texto por modelo fixo, com os mesmos marcadores e o mesmo validador. A demo funciona sem a chave do Gemini.

---

7. Ética, governança e segurança

[PENDENTE: texto final · NA5, Náthally, sáb 07 a dom 08/11] *Esta seção é a base técnica (`docs/etica.md`), atualizada em 06/11. A Náthally reescreve para a banca e completa a viabilidade.*

7.1 O risco principal: número inventado

O LLM pode inventar ou arredondar um número, e o vendedor levaria um dado falso para a reunião. Por isso o LLM só escreve marcadores e o validador (`checar()` e `validar_e_preencher()`, `raiox/ia.py`) barra:

- algarismos de qualquer escrita (inclusive ½ e ²);
- números e quantidades por extenso: "dez", "o dobro", "metade" e, desde o PR #63 (05/11, issue #50), também "dobrou", "triplicou", "um quarto" e "meio ponto" ("quarto trimestre" e "duplicatas" continuam liberados);
- marcadores que não estão na lista da empresa.

Se o resumo tiver um desses, ele sai inteiro; perguntas e lacunas saem uma a uma; tudo o que sai fica registrado. **Resultado:** nos 10 raio-x da avaliação, **0 trechos removidos** (seção 8). Isso quer dizer que o Gemini seguiu a regra e não escreveu número; **não** quer dizer que o texto está certo (7.2).

7.2 O que o validador não pega

O validador olha a **forma** do texto (tem número? o marcador existe?), não o **sentido**. Conferido em 06/11 com `checar()`: "A receita dobrou" é barrada, mas as duas frases abaixo passam.

- **Marcador certo no indicador errado:** em "A margem EBIT de `{endividamento}` está acima do grupo", o marcador existe e é permitido, então a frase passa, e a tela mostraria o endividamento como se fosse a margem. O valor é verdadeiro, mas está no lugar errado. O que protege: a regra do prompt (nome do indicador antes do marcador dele) e o cartão de cada indicador na tela, com o valor e a fonte.
- **Afirmação falsa sem número:** "A empresa perdeu clientes para a concorrência" não tem número nem marcador e passa, mesmo que seja falsa. O mesmo vale para:
  - pergunta com suposição falsa (ex.: supor que os custos explicam uma margem baixa);
  - "acima" ou "abaixo" trocado na frase: a posição é calculada por código, mas a palavra na frase é do LLM;

    - lacuna genérica ("quem decide a compra" serve para qualquer empresa);
    - interpretação de setor: o modelo pode associar a empresa a um negócio que ela não tem.

O que resolve, no fim, é a leitura humana. Por isso o raio-x é apoio, e não decisão (7.6).

7.3 Viés e limites do modelo de ML

- **Só companhias abertas:** empresas fechadas, pequenas ou médias não aparecem. A ferramenta serve para grandes contas.
- **Empresas pequenas:** as 31 com receita abaixo de R$ 10 mi recebem um grupo sem terem ajudado a formá-lo; para elas, a comparação é menos confiável.
- **Extremos cortados só no modelo:** os números mostrados são os reais, mas uma empresa muito fora da curva fica num grupo que não a representa bem.
- **Perfil financeiro, não setor:** com os dados de 05/11, as parecidas da WEG (máquinas) incluem Cemig e Copel (energia), Votorantim Cimentos e Telefônica: empresas grandes, rentáveis e pouco endividadas, mas de outros setores. Isso serve para prospectar perfis parecidos, mas não são concorrentes.
- **Silhueta 0,286:** os grupos se sobrepõem. É uma régua de comparação, não uma classificação exata.
- **Os 10 casos da avaliação caem no mesmo grupo** (o maior, com 312 empresas e receita mediana de R$ 3,6 bi). Receita e ativo saem "acima do grupo" nos 10, e a Petrobras (R$ 497,5 bi de receita) é comparada com a mesma mediana da Camil (R$ 11,1 bi): a comparação por porte diz pouco para empresas grandes (seção 6.2, issue #60).

7.4 Confiabilidade dos dados

- **Dado de até um ano atrás:** a DFP é anual; resultado trimestral não entra. O ano aparece em cada número.
- **Fonte em cada número:** cada indicador mostra a conta da DFP de onde veio, para o vendedor conferir.
- **Conferência contra o RI** (Marcos, 03/11, `avaliacao/conferencia.csv`): 13 valores de 5 empresas (WEG, Camil, Magalu, RD Saúde e CSN), todos com diferença de 0,00%.
- **A conferência manual** (Náthally) deu 7 de 10 em 29/10 e **8 de 10 em 05/11**: em 8 dos 10 casos, os 6 indicadores mostrados batem com os que ela calculou dos documentos da empresa (critério: receita e ativo com até 1% de diferença; percentuais com até 0,15 ponto). A Camil era um erro nosso (o ano fiscal), corrigido no PR #46. Esse "8 de 10" mede os **números** e não tem relação com os "0 trechos removidos" do validador, que mede o **texto** do Gemini (seção 8.1). As 2 diferenças que sobram são de **definição contábil**, conferidas nos PDFs usados por ela:
    - **RD Saúde:** a conferência usou a tabela "Pré-IFRS 16" do Relatório da Administração, que está no PDF da DFP 2025 (p. 48 da DFP) e tira os aluguéis das lojas: ativo R$ 20,6 bi, endividamento 62,44%, margem EBIT 5,27% (EBIT ajustado). O sistema usa a DFP oficial, com IFRS 16: ativo R$ 25,2 bi (com R$ 4,3 bi de direito de uso das lojas), 70,9% e 6,2%.
    - **Magazine Luiza:** os 5,81% da conferência saem do EBIT oficial (R$ 1.918,7 mi) sem as perdas de créditos esperadas e sem a equivalência patrimonial; o sistema usa a linha oficial da DRE (4,96%). Reconstrução nossa; falta a Náthally confirmar.
- **Número oficial × "ajustado":** empresas divulgam no release números "ajustados" ou "Pré-IFRS 16", e o vendedor pode ouvi-los na reunião. O raio-x mostra o número contábil oficial, igual para as 595 empresas, que pode ser diferente.

7.5 Segurança de dados

- **Chave do Gemini** só no `.env`, fora do Git. No Terraform, o `.env` é montado só para leitura e a chave não passa por variável, então não fica no `terraform.tfstate`. Nenhuma chave em todo o histórico do Git (busca pelo padrão de chave, 29/10).

- **Ponto fraco conhecido:** a senha do PostgreSQL local passa por variável do Terraform e fica no `terraform.tfstate`, que não vai para o Git. O banco só aceita conexões do próprio computador (`127.0.0.1`).
- **A tela só abre no próprio computador** (`127.0.0.1`), no `docker compose` e no Terraform. Até o PR #47 (04/11, issue #44), o compose abria a tela para a rede toda: com a IA ligada, qualquer um no mesmo Wi-Fi abria a tela e gastava crédito.
- **O erro técnico da IA não aparece para o vendedor:** o aviso tem uma frase, e o erro do Google vai para "Detalhes técnicos" e para o log (PR #47, issue #38).
- **O que vai para o Gemini:** o setor, os indicadores já formatados com a posição, o tamanho do grupo, o produto e o objetivo. Nem o nome da empresa vai (`montar()`, `raiox/ia.py`). A chave do projeto usa o plano pago (pré-pago, com cobrança), e os termos da API do Gemini para os serviços pagos ("Gemini API Additional Terms of Service", em vigor desde 23/03/2026, conferidos em 06/11) dizem que o Google **não usa os prompts nem as respostas para melhorar os produtos dele**; guarda os registros por um tempo limitado, só para detectar abuso e por exigência legal, e pode armazená-los em qualquer país. No plano gratuito é o contrário: o conteúdo pode ser lido por revisores humanos e usado para melhorar os produtos.
- **O que fica gravado:** a tabela `consultas` guarda empresa, produto, objetivo, tempo e custo. Não há dado pessoal, mas o produto e o objetivo são texto livre: o vendedor não deve escrever nome de pessoa ou dado sigiloso ali.
- **Travas na IA de programação:** a IA que ajudou a escrever o código não lê o `.env`, não faz commit de dados nem de chaves e pergunta antes do merge (seção 9).

7.6 Uso responsável

- **Apoio, não decisão:** o raio-x prepara a primeira reunião; o vendedor confere antes de usar. A tela avisa: "Confira antes de usar".
- **Não é recomendação de investimento:** o mesmo aviso, na tela.
- **Se a IA falhar, a ferramenta continua:** a tela monta o texto sem IA, com os mesmos números, e avisa. Conferido em 03/11 com uma chave inválida: WEG gerada sem IA e consulta gravada com custo 0. Desde o PR #47, a tela só diz que o texto foi escrito por IA quando o Gemini respondeu (issue #39).
- **Custo acompanhado:** cada consulta grava os tokens e o custo.

7.7 Viabilidade

- **Custo estimado da API por raio-x:** US$ 0,001185 em média (seção 8), calculado com os tokens de cada chamada e o preço oficial; não inclui o computador onde a aplicação roda.
- **Tempo para gerar um raio-x:** 2,15 s em média (rodada de 05/11), contando a montagem dos indicadores, a chamada ao Gemini e a validação.
- **Manutenção:** a DFP é anual; a base é recarregada uma vez por ano com 2 comandos (`scripts/carregar_dfp.py` e `scripts/indicadores.py`), e o K-means com `python -m raiox.segmentos`.
- **Ganho para o vendedor (ROI):** não medido. Sem um tempo manual comparável, não afirmamos redução de tempo (seção 1). **[PENDENTE: ROI · NA3, Náthally]**

---

8. Métricas

8.1 Avaliação com 10 casos reais (`avaliacao/resultados.csv`)

10 raio-x com o Gemini, um por caso de `avaliacao/casos_avaliacao.csv` (empresa, produto e objetivo escritos pela Náthally): Camil, CSN, Magazine Luiza, Petrobras, Embraer, Suzano, Raia Drogasil, Localiza, WEG e Telefônica. A 1ª rodada foi em 29/10 (PR #20); a de hoje, em 05/11 (PR #58), com os dados depois dos PRs #46 e #59.

São duas medidas diferentes, que não devem ser somadas nem confundidas:

o que mede	resultado	de onde vem
números certos: os 6 indicadores mostrados batem com a conferência manual da Náthally	**8 de 10 casos** (as 2 diferenças são de definição contábil, seção 7.4)	conferência manual de 05/11
texto sem número: trechos do Gemini removidos pelo validador	**0 trechos** em 10 casos	coluna `n_removidos`

O "0 removidos" não prova que o texto está certo: o validador não pega marcador no lugar errado nem afirmação falsa sem número (seção 7.2). O "8 de 10" não depende do Gemini: os números vêm da tabela, com ou sem IA.

métrica (coluna do `resultados.csv`)	resultado
raio-x gerados	10 de 10, todos com o Gemini
custo estimado da API (`custo_usd`)	US$ 0,001185 em média (de 0,001100 a 0,001216); US$ 0,011847 no total
tempo para gerar (`tempo_s`)	2,15 s em média (de 1,9 a 2,8 s), contando a montagem dos indicadores, a chamada ao Gemini e a validação
tokens por raio-x	2.262 de entrada e 412,8 de saída, em média

O custo é calculado com os tokens reais de cada chamada e o preço da página oficial do Google (US$ 0,25 por milhão de tokens de entrada e US$ 1,50 por milhão de saída, conferido em 20/10/2026). É uma estimativa: a fatura do Google não foi conferida caso a caso. O tempo é medido dentro de `preparar_raio_x()` (`raiox/ia.py`); não inclui a tela nem a pausa de 1 s entre um caso e outro.

Os 10 raio-x usam os dados e os grupos de 05/11: a Camil já com o exercício certo (mar/2025 a fev/2026) e os 10 casos no grupo de 312 empresas. Na 1ª rodada (29/10), com os dados antigos, os números eram parecidos: US$ 0,0118 no total, 2,2 s e 0 removidos.

8.2 Conferência dos números contra o RI (`avaliacao/conferencia.csv`)

empresa	valores conferidos	diferença
WEG	receita, EBIT, lucro líquido, ativo total, patrimônio líquido	0,00%
Camil	receita (exercício de mar/2025 a fev/2026)	0,00%
Magazine Luiza	receita, EBIT	0,00%
RD Saúde	receita, EBIT, ativo total, patrimônio líquido	0,00%
CSN	receita	0,00%

13 valores de 5 empresas, cada um com o documento do RI de onde veio (coluna `fonte`); 9 deles trazem também a página. O ativo e o patrimônio líquido da RD Saúde vêm da coluna comparativa de 31/12/2025 do ITR de 30/06/2026.

8.3 Qualidade do código

- Testes automáticos: 256 passando, nenhum pulado (06/11, Mac do Eduardo, com o PostgreSQL do compose ligado). Os testes não chamam a API.
- O CI roda os testes em todo pull request, com um PostgreSQL só para eles; a `main` só recebe mudanças por PR com o CI verde.

9. Como usamos IA para programar (vibecoding)

O time é iniciante: três pessoas programaram com o Claude Code (o Miguel começou com o Codex) e a Náthally não usou IA para código. A IA escreveu muito do código; **quem responde por ele é a pessoa**. Para isso valer, todo trabalho seguiu o mesmo caminho:

1. **Começo:** o comando `/inicio-de-sessao` cria uma branch a partir da `main` e faz a IA ler os arquivos do professor e o estado do projeto antes de mexer em qualquer coisa.
2. **Durante:** a IA segue o `CLAUDE.md` (donos de cada pasta, regra de ouro, contratos) e o `REGRAS-IA.md` (o que nunca vai para uma IA: chave, senha, dados pessoais). Toda afirmação sobre o código vem com arquivo e linha, ou com um comando que prova.
3. **Fim:** `/fim-de-sessao` roda os testes, escreve na descrição do PR o que mudou e abre o PR (desde 05/11, só o Eduardo edita as notas do projeto, uma vez por dia, para os PRs não brigarem pelo mesmo arquivo). O CI roda os testes de novo; um segundo Claude (o `revisor`), que não escreveu o código, lê o diff; o merge só acontece depois de um "pode" da pessoa.
4. **Travas:** as regras que custam caro quebrar viraram bloqueios automáticos (`.claude/settings.json` e `.claude/hooks/guarda.py`): a IA não lê o `.env`, não apaga trabalho no Git, não faz commit na `main` nem com dados ou chaves, e pergunta antes do merge. Na estreia, o `revisor` achou um jeito de vazar a chave que o autor não tinha visto; virou teste.
5. **No PR, duas linhas obrigatórias:** o que foi feito com IA e o que o autor entendeu ou conferiu.

Os arquivos de prompts do vibecoding (`requisitos_projeto.MD`, Aplicação) estão no repositório e listados no `README.md`: `CLAUDE.md`, `AGENTS.md`, `REGRAS-IA.md`, `.claude/skills/`, `.claude/agents/revisor.md`, `.claude/settings.json`, `.claude/hooks/guarda.py`, `.githooks/` e `.github/pull_request_template.md`. O prompt do produto (o que o Gemini recebe) é outro: `avaliacao/regras_prompt.md`.

10. Lições aprendidas

- **Número bonito pode enganar:** a silhueta de 0,77 media só a separação de 9 empresas extremas.
- **Teste que passa nem sempre testa:** dois testes passavam com o campo vazio. Passamos a estragar o código de propósito para ver o teste falhar.
- **Teste pulado não é teste que passou:** o CI ficou verde com 17 testes de banco pulados, porque não havia PostgreSQL nele. Agora o CI sobe o banco e lista os pulados.
- **A fonte vale mais que o resumo da fonte:** uma nota interna resumia o guia e virou "verdade", até para a IA, que disse que o Terraform não era preciso. Os arquivos do professor passaram a ficar no repositório e a ser lidos em toda sessão.
- **Branch longa vira retrabalho:** três vezes alguém teve de trazer à mão o que estava numa branch antiga. Agora toda sessão começa da `main`.
- **Contrato antes de código:** os erros mais caros (CSV com `;`, código CVM como texto) foram de formato entre as partes.

Apêndice A · De onde vem cada número

número neste documento	fonte	como conferir
595 empresas com indicadores	`data/indicadores.csv` (gerado, fora do Git)	`python -c "import pandas as pd; print(len(pd.read_csv('data/indicadores.csv')))"`
384.591 linhas de contas; carga em 1 min 48 s	carga do Marcos em 03/11 (`docs/REQUISITOS.md`, R2); mesmo total na carga de 05/11	`python -c "import pandas as pd; print(len(pd.read_csv('data/contas.csv')))"` → 384591

número neste documento	fonte	como conferir
k = 4; silhueta 0,286; grupos 60, 310, 88 e 106; 564 no treino; silhueta dos outros k	`segmentar()` com os dados de 05/11, conferido em 06/11	sem gravar nada: `python -c "import pandas as pd; from raiox import segmentos as s; df = pd.read_csv('data/indicadores.csv'); out, sil, k = s.segmentar(df); b = s.treino(df); print(k, round(sil[k], 3), out.set_index('cd_cvm').loc[b.cd_cvm, 'grupo'].value_counts().sort_index().tolist())"` → `4 0.286 [60, 310, 88, 106]`. O `python -m raiox.segmentos` mostra os grupos com todas as 595 empresas e grava de novo os PNG e o `data/segmentos.csv`
10 de 10 casos no grupo de 312 empresas (R$ 284 mil a R$ 497,5 bi; mediana R$ 3,6 bi); receita e ativo "acima" nos 10	`data/segmentos.csv` e `data/indicadores.csv` de 05/11; `avaliacao/resultados.csv`	campo `grupo` e `posicao` de cada raio-x em `raio_x_json`; issue #60
567 de 595 num grupo só; silhueta 0,77 antes	ED1 e ED4 (27 e 28/10), `docs/HISTORICO.md`	`docs/graficos/silhueta_antes_ed4.png`
31 empresas abaixo de R$ 10 mi (52%); 564 acima (4%)	`scripts/avaliar_corte_receita.py`, 03/11	rodar o script
receita da Camil: R$ 12,26 bi → R$ 11,12 bi; 9 empresas mudaram	PR #46 (`docs/PLANO.md`, seção 0)	11,12 bi: `avaliacao/conferencia.csv`, linha da Camil; 12,26 bi (antes): `git show 8bfb991:avaliacao/resultados.csv`, caso 1 (`valor_num` da receita, em R$ milhões)
nenhum "erro" e 179 "atenção" em 98 empresas	`raiox/checagem.py` com os dados de 05/11 (rodado em 06/11)	`python -m raiox.checagem data/indicadores.csv data/contas.csv`
10 raio-x, 0 removidos, US$ 0,011847 no total, US$ 0,001185 em média, 2,15 s, tokens	`avaliacao/resultados.csv` (rodada de 05/11, PR #58)	`python -c "import pandas as pd; r = pd.read_csv('avaliacao/resultados.csv'); print(r.n_removidos.sum(), r.custo_usd.sum(), r.custo_usd.mean(), r.tempo_s.mean())"`
"dobrou" barrado; marcador no indicador errado e afirmação sem número passam	`checar()`, `raiox/ia.py`, conferido em 06/11	`python -c "from raiox.ia import checar; print(checar('A margem EBIT de {endividamento} está acima do grupo.', {'endividamento'}))"` → `None`
US$ 0,25 e US$ 1,50 por milhão de tokens	`PRECO_US_POR_MILHAO`, `raiox/ia.py`	página oficial de preços do Google (20/10/2026)
13 valores de 5 empresas, 0,00%	`avaliacao/conferencia.csv`	coluna `diferenca_pct`
7 de 10 (29/10) e 8 de 10 (05/11) na conferência manual	Náthally; ED16 (`docs/PLANO.md`, seção 0)	`revisao_manual.md`, na branch `feat/metricas`, contra os raio-x de `avaliacao/resultados.csv`

número neste documento	fonte	como conferir
RD Saúde Pré-IFRS 16: ativo R$ 20.630,8 mi, PL R$ 7.749,6 mi, EBIT ajustado R$ 2.331,9 mi	PDF da DFP 2025 da RD (link da Náthally), Relatório da Administração, p. 48 da DFP	tabela "Pré-IFRS 16 / IFRS 16"
Magalu: EBIT R$ 1.918,7 mi; perdas de crédito R$ 455,8 mi; equivalência R$ 127,3 mi	DRE consolidada da DFP 2025, PDF p. 13	(1.918,7 + 455,8 − 127,3) ÷ 38.703,4 = 5,81%
WEG com o Gemini: US$ 0,0011	demo de 03/11 (`docs/HISTORICO.md`)	tabela `consultas` do banco da demo
15 s por tentativa, 2 tentativas, `temperature=0.2`	`TEMPO_LIMITE_S`, `TENTATIVAS`, `raiox/ia.py`	ler o arquivo
banco desiste em 5 s	`TEMPO_LIMITE_S`, `raiox/banco.py`	ler o arquivo
256 testes passando, nenhum pulado	Mac do Eduardo, 06/11, branch do PR #49 com a `main` mesclada	`python -m pytest -q -rs` com o PostgreSQL ligado

Apêndice B · Pendências desta versão (sai da versão final)

o que falta	de quem	quando
ROI: 1 raio-x montado à mão e cronometrado, contra a ferramenta (seções 1 e 7.7)	Náthally (NA3)	o quanto antes; sem ele, o documento não fala em ganho de tempo
texto final de ética na seção 7 e a viabilidade	Náthally (NA5)	sáb 07 a dom 08/11
tag `v1.0` e datas reais do congelamento (seção 2); números do Apêndice A conferidos de novo na `v1.0`	Eduardo	seg 09/11
data e horário da banca; resposta à pergunta 3 (seção 6.3)	professor (o Eduardo pergunta)	—
leitura do documento inteiro (seção 4 contra o BPMN; seção 3 contra a EDA)	Marcos	sáb 07/11