PROJETO B · TRILHA IA APLICADA · EQUIPE DE 4 · 20/10 A 15/11/2026

Raio-X Comercial

Antes da primeira reunião com uma grande empresa, o vendedor digita o nome dela, diz o que vende e para que é a reunião. Em segundos recebe o perfil financeiro da empresa, a comparação com empresas parecidas, perguntas ligadas ao produto dele, o que os números não dizem e uma lista de empresas parecidas para prospectar.

> O texto é escrito por IA, mas nenhum número é escrito pela IA. Todos vêm da CVM e mostram de onde saíram.

Fonte: demonstrações financeiras da CVM | ML: K-means + vizinhos | GenAI: LLM por API com saída estruturada | Demo pronta: sex 06/11



Produto e retorno Como funciona Dados IA API Quem faz o quê O que estudar Tarefas semanais Contratos Gestão Medição Escopo Verificado? Glossário Apresentação Resumo

PARA TODOS, BASE DO PITCH DA NÁTHALLY

O problema, quem usa e quanto vale

A banca tem especialistas da TCS, uma empresa que vende serviços de TI para grandes empresas. Quem usaria este produto é exatamente o tipo de profissional que eles têm dentro de casa.

QUEM USA

Executivo de contas B2B

Vende produtos ou serviços para empresas grandes. Antes da primeira reunião precisa entender o tamanho da empresa, se ela está crescendo, se a margem está apertada e se está endividada. Isso muda o que ele vai oferecer e como.

A DOR

Pesquisa manual e pela metade

Hoje ele abre o site de relações com investidores, procura os números, tenta comparar com o setor e pensa em perguntas. Leva tempo, cada vendedor faz de um jeito e a comparação com empresas parecidas quase nunca acontece.

O QUE ENTREGAMOS

Raio-x em segundos

- 6 indicadores com fonte na CVM
- Posição contra o grupo de empresas parecidas
- 3 a 5 perguntas ligadas ao produto do vendedor
- O que os números não dizem
- 5 empresas parecidas para prospectar

Conta do retorno

```
economia por mês = reuniões por mês
                 × (tempo manual − tempo com a ferramenta
                 × custo da hora do executivo

custo por mês    = raio-x por mês × custo por raio-x
```

Exemplo com números hipotéticos, só para entender a conta: 8 primeiras reuniões por mês, 45 min à mão e 10 min com a ferramenta dão 8 × 35 min = 4 h 40 min por mês por executivo. Na apresentação esses números são trocados pelos que a Náthally medir.

Objeções que a banca pode fazer

- **“Sites gratuitos já mostram indicadores.”** Mostram o número solto. Não comparam com empresas de perfil parecido, não sugerem perguntas ligadas ao que você vende e não listam empresas para prospectar.
- **“E se a IA inventar?”** A IA não escreve números; um validador rejeita qualquer dígito. Comparações (acima ou abaixo do grupo) são calculadas por código. Medimos os acertos.
- **“Os dados são velhos.”** São do último exercício anual entregue à CVM, e o ano aparece em cada número.

- **“É recomendação de investimento?”** Não. É preparação comercial, e a tela avisa isso.
- **“Só empresas abertas?”** Sim, é um limite assumido. São as maiores compradoras; empresas fechadas exigiriam outra fonte.

O SISTEMA INTEIRO EM SEIS PASSOS

Como funciona

Os três primeiros passos rodam uma vez, antes de qualquer consulta, e geram tabelas. Os três últimos rodam a cada uso. Em cada passo há um arquivo que você abre e confere sem ler código.

Preparação roda uma vez; refaz quando sair DFP nova

1 **Baixar e limpar** Marcos

Baixa as demonstrações financeiras anuais (DFP) de 2023 a 2025 e o cadastro da CVM. Lê com Pandas, fica só com a versão mais recente e o exercício certo, corrige a escala.

`contas.csv (uma linha por empresa × conta × ano)`

CONFERE quantas empresas têm receita e se os nomes das contas batem

2 **Calcular indicadores** Marcos

Uma linha por empresa com 6 indicadores do último ano. Grava em SQL. Este passo é a base de tudo.

`indicadores.csv · catalogo.db`

CONFERE abre 3 empresas que você conhece e compara a receita com o site de RI delas

3 **Agrupar e achar parecidas** Eduardo ML

K-means separa as empresas em grupos de perfil financeiro parecido. Vizinhos mais próximos encontram as 5 empresas mais parecidas com cada uma.

`segmentos.csv (grupo, medianas, percentis, parecidas)`

CONFERE olha 2 grupos: as empresas fazem sentido juntas?

Consulta a cada uso, alguns segundos

4 **Escolher na tela** Miguel vendedor

Digita parte do nome, escolhe a empresa, escreve o produto e o objetivo da reunião.

`cd_cvm, produto, objetivo`

5 **Escrever o raio-x** Eduardo regras: Náthally GenAI

O código monta uma entrada com os indicadores, a posição contra o grupo, o produto e o objetivo. O LLM devolve resumo, perguntas e lacunas em campos fixos, usando marcadores como `{margem_ebit}` no lugar dos números. O validador rejeita qualquer dígito; o código troca os marcadores pelos valores reais.

`raio-x em JSON + tokens + tempo`

CONFERE quantos textos o validador rejeitou e por quê

6 **Mostrar, revisar e medir** Miguel Náthally

A tela mostra o raio-x com a fonte de cada número. O vendedor revisa antes de usar. Cada consulta fica registrada em SQL; a Náthally usa esses registros para medir tempo, custo e qualidade.

`tela + linha na tabela consultas`

CONFERE tempo de resposta e custo por raio-x

Miguel

Tudo roda dentro de um contêiner Docker. O Terraform cria a imagem, o contêiner, a porta 8501 e o volume onde ficam `catalogo.db` e `segmentos.csv`. A chave da API entra como variável, nunca no código.

RESPONSÁVEL: MARCOS

Os dados

Três arquivos da CVM, todos CSV estruturado e públicos. O cadastro dá a lista de empresas para a busca. A DFP dá os números. Nada de PDF.

ARQUIVO	O QUE TEM	PARA QUÊ
`cad_cia_aberta.csv`	Companhias abertas: código CVM, nome, CNPJ, situação, setor	Busca por nome e setor

`dfp_cia_aberta_2023.zip`
`dfp_cia_aberta_2024.zip`
`dfp_cia_aberta_2025.zip`
	CSVs por demonstração. Usamos `DRE_con` (resultado), `BPA_con` (ativo) e `BPP_con` (passivo e patrimônio). Colunas: `CD_CVM, DENOM_CIA, VERSAO, ESCALA_MOEDA, ORDEM_EXERC, DT_FIM_EXERC, CD_CONTA, DS_CONTA, VL_CONTA`	Receita, resultado, lucro, ativo, patrimônio

Os 6 indicadores

INDICADOR	FÓRMULA	CONTAS (A CONFERIR NA S1)	O QUE DIZ AO VENDEDOR
Receita líquida	valor da conta, último ano	`DRE 3.01`	Tamanho da empresa
Crescimento em 2 anos	receita 2025 ÷ receita 2023 – 1	`DRE 3.01 (DFP 2025 e DFP 2023)`	Está expandindo ou encolhendo
Margem EBIT	resultado antes do resultado financeiro e dos tributos ÷ receita	`DRE 3.05 ÷ 3.01`	Pressão de custo na operação
Margem líquida	lucro do período ÷ receita	`DRE 3.11 ÷ 3.01`	Sobra no fim, depois de juros e impostos
Ativo total	valor da conta, último ano	`BPA 1`	Tamanho pelo que a empresa tem
Endividamento	1 – patrimônio líquido ÷ ativo total	`BPP 2.03 e BPA 1`	Quanto depende de terceiros; afeta apetite para investir

Regras de limpeza, na ordem

1. Ler com `sep=";"`, `encoding="latin-1"`, `decimal=","` e `CD_CONTA` como texto.

Por que isto é a parte crítica

Se a tabela de indicadores estiver errada, todo o resto fica errado com cara de certo. Por isso o Marcos confere 5 empresas contra o site de

2. Ficar só com `ORDEM_EXERC == "ÚLTIMO"` . Sem isso, cada conta aparece duas vezes.
3. Por empresa, ficar só com a maior `VERSAO` (reapresentações).
4. Converter a escala: se `ESCALA_MOEDA` for `MIL` , multiplicar por 1.000.
5. Usar o consolidado; se a empresa não tiver, usar o individual (`_ind`) e anotar a origem.
6. Excluir quem não tem receita de venda na conta 3.01 (bancos e seguradoras usam outro plano de contas) e quem tem receita zero ou negativa.
7. Nulos: se faltar a receita de 2023, o crescimento fica vazio e a tela mostra “sem dado”. Não inventar.

relações com investidores delas na S2, e a Náthally confere mais 10 na S3.

É também a parte que mais pontua nos requisitos de Pandas: limpeza, nulos, versões, escalas, junção de tabelas.

Se o Marcos travar em Pandas, o Eduardo assume o cálculo dos indicadores e ele fica com SQL, gráficos e BPMN.

Primeira tarefa do Marcos: verificar_dfp.py (cerca de 1 h)

NÃO TESTADO AQUI · RODAR E AJUSTAR

```
# Responde: quantas empresas têm receita na DFP 2025, e com que nomes de conta?
# pip install pandas requests
import io, zipfile, requests, pandas as pd

URL = "https://dados.cvm.gov.br/dados/CIA_ABERTA/DOC/DFP/DADOS/dfp_cia_aberta_2025.zip"
z = zipfile.ZipFile(io.BytesIO(requests.get(URL, timeout=180).content))
print(z.namelist())                                  # nomes dos CSVs dentro do zip

dre = pd.read_csv(z.open("dfp_cia_aberta_DRE_con_2025.csv"), sep=";",
                  encoding="latin-1", decimal=",", dtype={"CD_CONTA": str})
print(dre.columns.tolist())

dre = dre[dre["ORDEM_EXERC"] == "ÚLTIMO"]
dre = dre[dre["VERSAO"] == dre.groupby("CD_CVM")["VERSAO"].transform("max")]

rec = dre[dre["CD_CONTA"] == "3.01"]
print("Empresas com conta 3.01:", rec["CD_CVM"].nunique())
print(rec["DS_CONTA"].value_counts().head(10))      # bancos aparecem com outro nome
```

```
print(rec["ESCALA_MOEDA"].value_counts())

# mostra as contas de uma empresa para conferir 3.05 e 3.11 no site de RI dela
uma = rec["CD_CVM"].iloc[0]
print(dre[dre["CD_CVM"] == uma][["DENOM_CIA", "CD_CONTA", "DS_CONTA", "VL_CONTA"]].head(15))
```

RESPONSÁVEL: EDUARDO · REGRAS DO TEXTO: NÁTHALLY

A parte de IA

Duas peças pequenas. O ML organiza as empresas em grupos e acha as parecidas. O LLM transforma a tabela em texto útil para o vendedor, sem poder mexer nos números.

ML · RODA UMA VEZ

Grupos e empresas parecidas

1. Variáveis: log da receita, crescimento em 2 anos, margem EBIT, margem líquida, endividamento.
2. Cortar extremos nos percentis 1 e 99 (uma margem de –500% distorce tudo).
3. Nulos: preencher com a mediana só para o modelo. A tela continua mostrando “sem dado”.
4. Padronizar com `StandardScaler`.
5. Rodar `KMeans` com k de 3 a 8 e escolher pela silhueta. Gráfico da silhueta vai para a apresentação.
6. Por grupo: mediana de cada indicador e percentil de cada empresa dentro do grupo.
7. `NearestNeighbors` com 6 vizinhos no mesmo espaço padronizado: a própria empresa mais as 5 parecidas.

São umas 30 linhas de scikit-learn. O K-means já foi visto no bloco 2 do

GENAI · A CADA CONSULTA

O texto, com a regra de ouro

1. O código monta a entrada: valor de cada indicador, mediana do grupo, posição (acima ou abaixo, calculada por código), produto e objetivo.
2. A instrução contém as regras da Náthally e exige campos fixos: resumo, perguntas, lacunas (o formato do C3).
3. **Regra de ouro:** o LLM escreve `{margem_ebit}` e `{margem_ebit_grupo}`, nunca o número.
4. Validador: se sobrar qualquer dígito fora dos marcadores, ou um marcador desconhecido, o item é removido e registrado.
5. O código troca os marcadores pelos valores formatados e grava tokens e tempo.

Uma única chain no LangChain: instrução → modelo → saída estruturada (Pydantic). Sem agente, sem memória, sem RAG no núcleo.

curso.

O QUE O LLM RECEBE (TRECHO)

```
{"empresa": "TRANSVALE LOGISTICA S.A.",
 "setor": "Transporte e logística", "ano": "2025",
 "produto": "software de roteirização e telemetria",
 "objetivo": "primeira conversa com a diretoria de operações
 "indicadores": {
   "margem_ebit": {"valor": "6,2%", "grupo": "11,8%",
                   "posicao": "abaixo"},
   "cresc_2a":    {"valor": "+18%", "grupo": "+9%",
                   "posicao": "acima"} }}
```

O QUE O LLM DEVOLVE, ANTES DE TROCAR OS MARCADORES

```
{"resumo": "Cresce acima do grupo ({cresc_2a} contra
   {cresc_2a_grupo}), mas com margem operacional abaixo
   ({margem_ebit} contra {margem_ebit_grupo}).",
 "perguntas": [{"texto": "Quais custos mais pesaram
   nesse crescimento, e onde a frota entra nisso?",
   "base": "margem_ebit"}],
 "lacunas": ["Quem decide a compra de tecnologia",
             "Fornecedor atual de roteirização"]}
```

ESCOLHA DA API · PREÇOS CONFERIDOS NAS PÁGINAS OFICIAIS EM 20/10/2026

Qual API usar e quanto custa

Recomendação: Google Gemini, modelo `gemini-3.1-flash-lite`, na camada gratuita durante o projeto. Custo zero para desenvolver e avaliar, aceita saída estruturada e tem integração pronta com LangChain. Se a camada gratuita limitar, troca-se de modelo mudando uma linha.

PROVEDOR	MODELO	ENTRADA · US$ POR 1M TOKENS	SAÍDA · US$ POR 1M TOKENS	GRATUITO?
Google	gemini-3.1-flash-lite	0,25	1,50	Sim, camada gratuita com limites de uso. Nela, os dados enviados podem ser usados pelo Google para melhorar produtos.
Google	gemini-3.5-flash-lite	0,30	2,50	Sim, mesma regra
OpenAI	gpt-6-luna	0,10	0,50	A página de preços não menciona
Anthropic	Claude Haiku	0,10	0,50	Pequeno crédito inicial para novos usuários (preço vale para entradas

5.5	até 100 mil tokens)

Custo de um raio-x

Estimativa: cerca de 2.000 tokens de entrada (instrução + indicadores) e 700 de saída.

```
Gemini 3.1 Flash-Lite, pago:
  2.000 × 0,25 ÷ 1.000.000 = US$ 0,0005
    700 × 1,50 ÷ 1.000.000 = US$ 0,00105
  total ≈ US$ 0,0016 por raio-x

1.000 raio-x (o projeto inteiro) ≈ US$ 1,60
Na camada gratuita: zero
```

Alguns modelos cobram tokens de “raciocínio” como saída. Por isso a conta da apresentação usa os tokens reais gravados no log, não esta estimativa.

Como configurar (Eduardo, 30 min)

1. Criar a chave no Google AI Studio.
2. Guardar em `.env` como `GOOGLE_API_KEY=...` e pôr `.env` no `.gitignore`.
3. `pip install langchain-google-genai python-dotenv`

```
from dotenv import load_dotenv; load_dotenv()
from langchain_google_genai import ChatGoogleGenerativeA

llm = ChatGoogleGenerativeAI(model="gemini-3.1-flash-lit
                             temperature=0.2)
gerador = llm.with_structured_output(RaioX)  # RaioX: mo
```

Se o curso der créditos de outro provedor, troca-se a classe (por exemplo `ChatOpenAI`) e o nome do modelo. O resto do código não muda.

O que a Náthally precisa saber da API

- **Token** é um pedaço de palavra. A API cobra por milhão de tokens, separando entrada (o que mandamos) e saída (o que o modelo escreve).
- **Custo de um raio-x** = tokens de entrada × preço de entrada + tokens de saída × preço de saída, dividido por 1.000.000. Os tokens de cada raio-x estão nas colunas `tokens_entrada` e `tokens_saida` do `resultados.csv`.
- **Camada gratuita** tem limite de pedidos por minuto e por dia. Na avaliação, rodar com pausa entre chamadas.
- **Privacidade:** na camada gratuita, o que enviamos pode ser usado pelo Google. Só enviamos dados públicos da CVM e produtos fictícios. Num uso real, com dados de clientes, seria preciso a camada paga. Isso entra no texto de ética.

RESPONSABILIDADES

Quem faz o quê

Cada pessoa tem uma entrega principal que outra pessoa consegue conferir abrindo um arquivo.

Marcos · Dados

Transformar os arquivos da CVM numa tabela confiável: uma linha por empresa, com os 6 indicadores do último ano.

ENTREGA indicadores.csv e catalogo.db (C1 e C2), funções de busca, gráficos de dados e o BPMN.

RECEBE Nada para começar. Na S3, os resultados da avaliação para os gráficos finais.

ESTUDA pandas.read_csv com sep, encoding, decimal e dtype · Filtros, groupby com transform, pivot_table e merge · sqlite3 e DataFrame.to_sql · O que é DRE e balanço (glossário da página) · bpmn.io para o BPMN (S3)

Eduardo · IA e gestão

Com a tabela de indicadores, achar o grupo e as empresas parecidas (ML) e fazer o LLM escrever o raio-x e as perguntas sem nunca digitar um número (GenAI). Coordenar a equipe pelas entregas de sexta.

ENTREGA segmentos.csv, ia.py com preparar_raio_x (C3), resultados.csv da avaliação e a justificativa técnica.

RECEBE indicadores.csv (C2) do Marcos; regras_prompt.md e casos_avaliacao.csv da Náthally.

ESTUDA Revisão de K-means e silhueta (bloco 2 do curso) · StandardScaler e NearestNeighbors do scikit-learn · Gemini no AI Studio e LangChain: ChatGoogleGenerativeAI e with_structured_output · Pydantic para os campos fixos · Regex básico para o validador (re.search, re.findall) · Significado de cada indicador (glossário)

Náthally · Produto e métricas

Vender e medir. Provar com números quem usa, quanto tempo economiza, quanto custa e quando erra, e contar essa história na apresentação. Ela monta o deck; cada um manda o conteúdo da parte que vai falar. Quase sem programar.

ENTREGA Persona e pitch; regras_prompt.md; tempo_manual.csv, casos_avaliacao.csv, revisao.csv, conferencia.csv e

Miguel · Tela e infraestrutura

Qualquer pessoa sobe o sistema com um comando e entende o raio-x sem ajuda.

ENTREGA app.py, Dockerfile, infra/main.tf, README e vídeo backup.

RECEBE dados.py (C1) do Marcos e ia.py (C3) do Eduardo. Até lá, usa os falsos.

	testes_usuarios.csv; conta de retorno e custo; texto de ética; roteiro e deck da apresentação (cada um manda o conteúdo da sua parte).
RECEBE	Raio-x gerados e resultados.csv (com tokens e tempo) do Eduardo; indicadores.csv do Marcos.
ESTUDA	Curso gratuito IA, Gen AI e Engenharia de Prompt (cerca de 1 h) · Glossário de indicadores da página · Como achar números no site de relações com investidores de uma empresa · Seção API da página: token, preço, conta de custo, camada gratuita · Pandas básico: read_csv, mean, groupby, value_counts

ESTUDA	Streamlit: text_input, selectbox, columns, metric, bar_chart, expander, spinner · Dockerfile: FROM, COPY, RUN pip install, CMD · Terraform com o provider kreuzwerker/docker: docker_image, docker_container, docker_volume · terraform init, apply e destroy; variável sensível para a chave da API

RECOMENDAÇÃO DE ESTUDO POR PESSOA

O que estudar

Estude só o que a tarefa da semana pede. A maior parte cabe na S1; o resto entra quando a tarefa chegar. Cada item diz por que serve e quanto tempo leva.

Marcos · Dados

1. 10 minutes to pandas (documentação oficial). Seleção, groupby, merge, pivot_table. É o que a limpeza usa. 2 h
2. Como analisar demonstrativos da CVM (Análise Macro). Explica exatamente os arquivos que ele vai abrir: nomes, colunas, armadilhas. 1 h
3. sqlite3 do Python (documentação oficial) e `DataFrame.to_sql` . Criar tabela, gravar, consultar com `LIKE` . 1,5 h
4. Glossário desta página: DRE, balanço, consolidado e os 6 indicadores. 0,5 h

Eduardo · IA e gestão

1. Análise de silhueta com K-means (exemplo oficial do scikit-learn). Escolher o número de grupos e fazer o gráfico da apresentação. 1 h
2. Documentação do scikit-learn sobre `StandardScaler` e `NearestNeighbors` . Padronizar e achar as 5 parecidas. 1 h
3. Saída estruturada no Gemini (documentação oficial, com exemplos em Pydantic). É o formato fixo do raio-x. 1 h
4. The Complete LangChain & RAG Developer Course 2026 (Udemy). Só os módulos de prompt templates e structured output; os de RAG ficam para a extensão. 2 h

5. Na S3: bpmn.io, editor gratuito de BPMN no navegador. 1 h

Pode pular: ML, LLM, Docker.

5. Expressões regulares básicas em Python (`re.search` , `re.findall`) para o validador. 0,5 h

Pode pular por agora: embeddings e RAG. Só se o mínimo estiver pronto em 06/11.

Náthally · Produto e métricas

1. Inteligência Artificial, Gen AI e Engenharia de Prompt (Udemy, gratuito). O que é um LLM e como escrever instruções. 1 h
2. Opcional: seções 1 a 3 de Engenharia de Prompts com IA (Udemy). Técnicas para as regras do texto. 2 h
3. Glossário desta página e o site de relações com investidores de 1 empresa: achar receita e lucro na mão. É a base do tempo manual. 1 h
4. Seção API desta página e a página oficial de preços do Gemini. Token, preço e conta de custo. 0,5 h
5. 10 minutes to pandas, só leitura de CSV, `value_counts` , `groupby` e `mean` . Para as métricas. 1 h

Pode pular: código de ML, LangChain, Docker.

Miguel · Tela e infraestrutura

1. Get started with Streamlit (documentação oficial). Fazer o “First steps”: widgets, colunas, gráficos. 2 h
2. Get started with Docker (documentação oficial). Tutorial para iniciantes e os conceitos de portas e volumes. 2 h
3. Terraform: Get Started com Docker (tutorial oficial da HashiCorp). Criar, mudar e destruir contêineres; variáveis. 2 h

Pode pular: ML, LLM, finanças além do glossário.

PARA ENVIAR A CADA PESSOA

Tarefas semanais

Escolha a pessoa e use “Copiar mensagem” para colar no WhatsApp. As horas são estimativas para quem está começando. Travou por mais de 2 horas, avisa o grupo.

Pessoa	S1 19–25/10	S2 26/10–01/11	S3 02–08/11	S4 09–15/11

Marcos Dados	**Provar os dados** **Pronto quando:** Mensagem no grupo com o número de empresas com receita em 2025 e os nomes das contas; contas.csv gerado.	**Indicadores reais** **Pronto quando:** indicadores.csv com centenas de linhas; 5 empresas conferidas com diferença menor que 1% na receita; buscar_empresas("vale") devolve resultados.	**Gráficos e BPMN** **Pronto quando:** Gráficos salvos em docs/graficos/; BPMN exportado em .bpmn e .png.	**Documentação** **Pronto quando:** documentacao.pdf no repositório; todo número dos gráficos vem de um CSV.
Eduardo IA e gestão	**Prova com tabela falsa** **Pronto quando:** Sex 23/10: 3 raio-x falsos gerados; um texto com dígito inserido de propósito foi rejeitado pelo validador.	**ia.py com dados reais** **Pronto quando:** python ia.py --cvm <código> imprime o raio-x completo; nenhum dígito vindo do LLM; tokens e tempo no resultado.	**Integrar e avaliar** **Pronto quando:** resultados.csv com 20 linhas; a demo roda pela tela para qualquer empresa com indicadores.	**Congelar e explicar** **Pronto quando:** Tag v1.0 no repositório; justificativa entregue ao Marcos.
Náthally Produto e métricas	**Entender o cliente e medir o antes** **Pronto quando:** tempo_manual.csv com 3 empresas; persona; regras v1; pitch de 30 s lido para o grupo na sexta.	**Preparar a medição** **Pronto quando:** 20 casos prontos; testes agendados; primeira conta de custo por raio-x; 5 tempos manuais.	**Medir de verdade** **Pronto quando:** Tabela de métricas que outra pessoa refaz com os mesmos CSVs; modelo do deck compartilhado com o grupo.	**Vender e montar o deck** **Pronto quando:** Deck completo até sex 13/11; todo número da apresentação bate com um CSV; ensaio dentro de 20 min.
Miguel Tela e infraestrutura	**Tela falsa num contêiner** **Pronto quando:** localhost:8501 abre a tela falsa dentro do contêiner.	**Terraform e falsos** **Pronto quando:** terraform apply sobe a tela; depois de destroy e apply, um arquivo em data/ continua lá.	**Integração** **Pronto quando:** A demo de 06/11 roda a partir de terraform apply; o colega subiu em menos de 15 min só com o README.	**Entrega** **Pronto quando:** Tag v1.0 roda do zero; vídeo salvo em dois lugares; conteúdo da demo entregue à Náthally.

Marcos · Dados | Eduardo · IA e gestão | Náthally · Produto e métricas | Miguel · Tela e infraestrutura

Marcos · Dados

Copiar mensagem

Transformar os arquivos da CVM numa tabela confiável: uma linha por empresa, com os 6 indicadores do último ano.

ENTREGA

indicadores.csv e catalogo.db (C1 e C2), funções de busca, gráficos de dados e o BPMN.

RECEBE

Nada para começar. Na S3, os resultados da avaliação para os gráficos finais.

ESTUDA

- pandas.read_csv com sep, encoding, decimal e dtype
- Filtros, groupby com transform, pivot_table e merge
- sqlite3 e DataFrame.to_sql
- O que é DRE e balanço (glossário da página)
- bpmn.io para o BPMN (S3)

S1 · 19–25/10 Provar os dados

~9 h

1. Estudar read_csv (sep, encoding, decimal, dtype), groupby e pivot_table (3 h).
2. Até qui 22/10: rodar verificar_dfp.py (seção Dados da página) e mandar no grupo quantas empresas têm a conta 3.01, quais nomes aparecem em DS_CONTA e quais escalas aparecem (1 h).
3. Escolher uma empresa conhecida e comparar as contas 3.01, 3.05 e 3.11 com o site de relações com investidores dela, para confirmar os códigos (1 h).
4. Começar carregar_dfp.py: baixar DFP 2023, 2024 e 2025; ler DRE, BPA e BPP consolidados; aplicar as regras de limpeza 1 a 4; salvar contas.csv (3 h).
5. Carregar o cadastro e criar a tabela empresas (1 h).

PRONTO QUANDO Mensagem no grupo com o número de empresas com receita em 2025 e os nomes das contas; contas.csv gerado.

S2 · 26/10–01/11 Indicadores reais

~9 h

1. indicadores.py: aplicar as regras 5 a 7 (individual quando faltar consolidado; excluir quem não tem receita de venda; nulos sem inventar) e calcular os 6 indicadores com as fórmulas da página (4 h)

2. Gravar empresas e indicadores no catalogo.db; dados.py com buscar_empresas no formato do C1 (2 h).
3. Conferir 5 empresas contra o site de RI e anotar em conferencia.csv (1 h).
4. Até dom 01/11: entregar indicadores.csv ao Eduardo e dados.py ao Miguel (1 h).
5. Avisar o grupo no mesmo dia se algum indicador sair estranho (margem acima de 100%, receita zero).

PRONTO QUANDO indicadores.csv com centenas de linhas; 5 empresas conferidas com diferença menor que 1% na receita; buscar_empresas("vale") devolve resultados.

S3 · 02–08/11 **Gráficos e BPMN** ~9 h

1. Ter 03/11: dados.py congelado (marco “três módulos prontos”).
2. avaliacao/graficos.ipynb: empresas por setor; cobertura; distribuição de margem e endividamento; tempo de resposta (4 h).
3. Tabela consultas e função registrar_consulta (1 h).
4. BPMN 2.0 no bpmn.io com raias Vendedor, Sistema e LLM (API externa); decisões “empresa tem dados?” e “texto passou no validador?”; revisão humana no fim (3 h).
5. Qui 05/11: apoio à integração (1 h).

PRONTO QUANDO Gráficos salvos em docs/graficos/; BPMN exportado em .bpmn e .png.

S4 · 09–15/11 **Documentação** ~6 h

1. Gráficos finais com os números da avaliação.
2. Montar docs/documentacao.pdf: BPMN + justificativa técnica (texto do Eduardo) + ética (texto da Náthally). Os textos chegam até qui 12/11.
3. Até qui 12/11: mandar à Náthally o conteúdo dos slides de BPMN e arquitetura (3 min) e conclusão (2 min); preparar a fala.

PRONTO QUANDO documentacao.pdf no repositório; todo número dos gráficos vem de um CSV.

O QUE PASSA DE UMA MÃO PARA OUTRA

Contratos

Salvem como `contratos.md` no repositório na primeira reunião. Enquanto o colega não entrega, cada um usa um arquivo falso no mesmo formato. Quem muda um formato avisa antes quem recebe.

C1 · dados.py

Marcos → Miguel

```
buscar_empresas(texto: str) -> list[dict]
# só ativas e com indicadores, ordenadas por nome
[{"cd_cvm": 99991,
  "nome": "TRANSVALE LOGISTICA S.A.",
  "setor": "Transporte e logística"}]

registrar_consulta(registro: dict) -> None
```

C2 · indicadores.csv

Marcos → Eduardo

```
# uma linha por empresa; valores em reais;
# margens e crescimento como fração (0.062 = 6,2%)
cd_cvm, nome, setor, ano,
receita, receita_2a_antes, cresc_2a,
margem_ebit, margem_liquida,
ativo_total, endividamento,
origem (con/ind), versao
```

C3 · ia.py

Eduardo → Miguel

```
preparar_raio_x(cd_cvm: int, produto: str,
                objetivo: str) -> dict
{"empresa": "...", "setor": "...", "ano": 2025,
 "indicadores": [{"id": "margem_ebit",
   "nome": "Margem EBIT", "valor": "6,2%",
   "grupo": "11,8%", "posicao": "abaixo",
   "fonte": "DFP 2025 · DRE consolidada · 3.05/3.01"}],
 "grupo": {"numero": 3, "tamanho": 41},
 "parecidas": [{"cd_cvm": 0, "nome": "...", "setor": "..
 "resumo": "...", "perguntas": [{"texto": "...",
   "base": "margem_ebit"}], "lacunas": ["..."],
 "removidos": [{"texto": "...", "motivo": "dígito"}]
```

C4 · pasta avaliacao/

Náthally ⇄ Eduardo

```
# Náthally escreve
regras_prompt.md
casos_avaliacao.csv   caso_id, cd_cvm, produto, objetivo
tempo_manual.csv      empresa, minutos, fontes
# Eduardo gera
resultados.csv        caso_id, raio_x_json, n_removidos,
                      tokens_entrada, tokens_saida,
                      custo_usd, tempo_s
# Náthally preenche
revisao.csv           caso_id, item, comparacao_certa,
                      ligada_ao_produto, clara, utilidade
conferencia.csv       cd_cvm, indicador, valor_sistema
```

```
  "uso": {"tokens_entrada": 1850, "tokens_saida": 640,
          "custo_usd": 0.0014, "tempo_s": 3.2}}
```

```
                          valor_ri, diferenca_pct
testes_usuarios.csv       pessoa_id, cargo, minutos,
                          utilidade, usaria, comentario
```

```
# estrutura do repositório
raio-x-comercial/
├─ app.py                    # Miguel · tela Streamlit
├─ dados.py                  # Marcos · C1
├─ ia.py                     # Eduardo · C3 (montar entrada, gerar, validar, preencher)
├─ scripts/                  # verificar_dfp.py, carregar_dfp.py, indicadores.py (P1) · segmentos.py (Eduardo)
├─ falsos/                   # tabela_falsa.csv, falso_dados.py, falso_ia.py
├─ prompts/regras_prompt.md# Náthally
├─ avaliacao/                # C4 + rodar_avaliacao.py + graficos.ipynb
├─ infra/main.tf             # Miguel · Terraform
├─ docs/                     # BPMN, gráficos, documentacao.pdf, deck, persona, pitch
├─ data/                     # volume: catalogo.db, segmentos.csv (fora do git)
├─ Dockerfile · requirements.txt · .env.example · .gitignore
└─ contratos.md · README.md
```

PARA O EDUARDO

Como gerenciar sem precisar ler o código de todo mundo

Você não precisa entender cada linha. Precisa saber qual arquivo cada pessoa deve gerar, abrir esse arquivo e conferir uma coisa simples. Se o arquivo não existe, a tarefa não está pronta.

S1 19–25/10

Confirmar dados e provar a IA com tabela falsa

S2 26/10–01/11

Cada peça funciona com dados reais

S3 02–08/11

Ligar tudo e medir

seg 02 *Feriado*

S4 09–15/11

Corrigir, entregar, ensaiar. Nada novo.

ter 20	**Contratos combinados; chave da API criada**
qui 22	**verificar_dfp.py rodado: quantas empresas têm receita**
sex 23	**Dados confirmados; raio-x falso funcionando; tempo manual medido**

qua 28	3 raio-x reais para a Náthally ajustar regras
dom 01	**indicadores.csv real; segmentos.csv; 20 casos de avaliação**

ter 03	**Três módulos prontos: dados, IA, tela + infra**
sex 06	**Demo ponta a ponta via terraform apply; testes com usuários**

ter 10	**Código congelado (v1.0)**
11–15	*Trabalho final do estágio*
qui 12	Conteúdo dos slides de todos com a Náthally
sex 13	**Avaliação final e vídeo backup**
sáb–dom	Dois ensaios de 20 min

O que você abre e confere em cada sexta

Sex 23/10 S1

Marcos Mensagem com o número de empresas com conta 3.01 em 2025 e os nomes das contas. Se forem centenas, o projeto está de pé.

Eduardo 3 raio-x gerados a partir da tabela falsa; um texto com dígito inserido de propósito foi rejeitado.

Náthally `tempo_manual.csv` com 3 empresas; persona; pitch de 30 s lido em voz alta.

Miguel Tela falsa abrindo em `localhost:8501` dentro do Docker.

Sex 30/10 e dom 01/11 S2

Marcos Abra `indicadores.csv` no Excel, filtre 3 empresas que você conhece e compare a receita com o site de RI. Diferença menor que 1%.

Eduardo Em `segmentos.csv`, olhe 2 grupos: estão juntas empresas de perfil parecido? Anote em 2 linhas por quê.

Náthally `casos_avaliacao.csv` com 20 linhas; testes com usuários agendados; regras v2.

Miguel `terraform apply` sobe a tela; depois de destroy e apply, o arquivo em `data/` continua lá.

Ter 03/11 e sex 06/11 S3

grupo	Roteiro da demo: buscar 3 empresas de setores diferentes, cada raio-x em poucos segundos, nenhum número sem fonte.
Náthally	`revisao.csv` preenchido para os 20 casos; pelo menos 3 testes com usuários feitos.
Eduardo	`resultados.csv` com tokens e tempo de cada caso.

Ter 10/11 e sex 13/11 S4

grupo	Tag v1.0 criada; avaliação final rodada nela; deck completo montado pela Náthally; vídeo salvo em dois lugares; ensaio cronometrado abaixo de 20 min.

Ritmo da equipe

- **Terça, 15 min:** cada um diz o que já roda, o que falta e o que trava.
- **Sexta, 30 min:** cada um mostra o "pronto quando" rodando. Relato não conta.
- **WhatsApp:** travou mais de 2 horas, avisa.

Perguntas para quem atrasou

- O que já roda? Me mostra.
- Qual é o próximo arquivo que você vai gerar?
- O que está travando, e quem do grupo pode ajudar?
- Dá para entregar uma versão menor até sexta?

Se acontecer, faça isto

- `22/10` Poucas empresas com receita (menos de 200): conferir se faltou ler o individual; se ainda assim for pouco, discutir no grupo na sexta antes de seguir.
- `01/11` `indicadores.csv` não saiu: o Eduardo assume os indicadores; o Marcos vai para SQL, gráficos e BPMN.
- `01/11` Camada gratuita limitando: ativar cobrança no Gemini (custo de centavos) ou trocar de modelo.
- `03/11` Algum módulo não passa no "pronto quando": voltar ao mínimo. Nenhum extra.
- `06/11` Demo não roda inteira: seg e ter da S4 só para isso; vídeo backup vira obrigatório.

RESPONSÁVEL: NÁTHALLY · COM OS ARQUIVOS DO EDUARDO E DO MARCOS

O que medimos e como

Estes números sustentam o pitch e a parte de governança. As metas são do time, não fatos: se um

número sair abaixo, ele aparece assim mesmo, com a explicação.

MÉTRICA	COMO MEDE	ARQUIVO	META DO TIME
Indicadores corretos	Conferir 10 empresas contra o site de RI	`conferencia.csv`	10 de 10 com diferença < 1%
Números escritos pelo LLM	Validador conta dígitos fora dos marcadores	`resultados.csv`	0 na tela
Comparação certa	Texto diz acima ou abaixo do grupo de acordo com a tabela	`revisao.csv`	≥ 95%
Perguntas ligadas ao produto	A pergunta usa o produto informado e um indicador?	`revisao.csv`	≥ 80%
Utilidade	Nota de 1 a 3 de quem vende, em 3 a 5 testes	`testes_usuarios.csv`	reportar a média
Tempo economizado	Minutos à mão × minutos com a ferramenta (ler e revisar incluídos)	`tempo_manual.csv` · `testes_usuarios.csv`	reportar a diferença
Custo por raio-x	Tokens reais × preço da tabela de API	`resultados.csv`	reportar em US$ e R$
Cobertura	Empresas ativas com raio-x disponível ÷ empresas ativas	`catalogo.db`	reportar
Tempo de resposta	Segundos por consulta	`tabela consultas`	reportar a mediana

Testes com usuários, sem complicar

3 a 5 pessoas que vendem ou já venderam para empresas (colegas do estágio, família, conhecidos). Cada teste leva 15 minutos: a pessoa escolhe uma empresa que conhece, usa a ferramenta, diz o que ajudou e o que faltou, dá uma nota de 1 a 3 e responde se usaria. Não guardamos o nome, só o cargo. Frases boas viram citação no deck, com permissão.

O QUE ENTRA E O QUE SAI

Mínimo, recomendado, extra e fora

O mínimo cobre todos os requisitos do guia. O extra só começa se o mínimo estiver rodando em 06/11.

Mínimo

Sem isto não apresenta

- Indicadores de todas as companhias não financeiras com DFP, em SQL
- Busca por nome
- Raio-x: 6 indicadores, posição no grupo, 3 a 5 perguntas, lacunas, 5 parecidas
- LLM sem números (validador)
- Docker + Terraform
- Medições da tabela acima e 3 testes com usuários
- BPMN, README, PDF de documentação, deck, vídeo

Recomendado

Barato, vale ponto

- Gráfico empresa × grupo na tela
- Receita dos 3 anos num gráfico
- Filtro “parecidas do mesmo setor”
- Aviso “não é recomendação de investimento” na tela

Extra

Só depois de 06/11

- Número de empregados (Formulário de Referência)
- RAG em releases de 5 empresas
- LLM dando nome aos grupos
- Exportar o raio-x

Fora

Decidido não fazer

- Recomendação de investimento ou preço de ação
- Dados de pessoas
- Notícias e pesquisa na internet
- Agente, memória, fine-tuning
- Bancos e seguradoras

REQUISITO DO GUIA	ONDE APARECE	DONO
BPMN 2.0	Vendedor → sistema → LLM → revisão humana, com decisões “empresa tem dados?” e “texto passou no validador?”	Marcos
Pandas: limpeza, nulos, estruturacão	Versões, exercício, escala, consolidado × individual, crescimento sem dado	Marcos

SQL	`catalogo.db` : empresas, indicadores, consultas	Marcos
Visualização explicativa	Empresas por setor, silhueta, grupos em 2D, métricas, gráfico na tela	Marcos Eduardo Miguel
Machine Learning	K-means + vizinhos mais próximos	Eduardo
GenAI: prompt, API, LangChain	Chain com saída estruturada, regras da Náthally, validador	Eduardo Náthally
Interface funcional	Streamlit	Miguel
Terraform ou contêiner	Docker + Terraform: imagem, contêiner, porta, volume	Miguel
Governança e ética	Medições, privacidade da API, limites, aviso de investimento	Náthally

PARA NÃO DEPENDER DE CONFIAR NESTA PÁGINA

O que está verificado e o que falta testar

AFIRMAÇÃO	SITUAÇÃO	COMO CONFERIR
Requisitos, entregáveis e critérios da banca	VERIFICADO	Guia do projeto, seções 2, 5, 6 e 7
DFP anual disponível de 2010 a 2026, um zip por ano	VERIFICADO	Repositório DFP da CVM
Nomes dos CSVs, colunas, separador, codificação e vírgula decimal	VERIFICADO	Fonte secundária: Análise Macro. O script imprime as colunas
Preços e camada gratuita das APIs	VERIFICADO	Páginas oficiais de preço do Google, OpenAI e Anthropic em 20/10/2026. Preços mudam: conferir antes da apresentação

Códigos de conta 3.01, 3.05, 3.11, 1 e 2.03	A TESTAR · 22/10	`verificar_dfp.py` mostra `DS_CONTA` ; comparar com o site de RI de uma empresa
Quantas empresas têm receita na DFP 2025	A TESTAR · 22/10	`verificar_dfp.py`
Bancos e seguradoras usam outro nome na conta 3.01	A TESTAR · 22/10	`value_counts` de `DS_CONTA` no script
Nomes das colunas do cadastro (código, nome, situação, setor)	A TESTAR · S1	Imprimir as colunas ao carregar o cadastro
Limites da camada gratuita do Gemini e nome exato do modelo	A TESTAR · S1	Google AI Studio, na criação da chave
Tokens reais por raio-x	A TESTAR · S2	Log gravado pelo `ia.py`

PARA TODOS

Glossário

Cada termo numa frase. Quem for apresentar precisa saber explicar os da sua parte.

CVM. Órgão que regula o mercado de capitais e publica os dados das companhias abertas.

Companhia aberta. Empresa registrada na CVM, que precisa publicar suas demonstrações.

DFP. Demonstrações Financeiras Padronizadas, entregues à CVM uma vez por ano.

DRE. Demonstração do resultado: receita, custos e lucro do ano.

Balanço (BPA e BPP). O que a empresa tem (ativo) e como isso é financiado (passivo e patrimônio líquido).

Consolidado e individual. Consolidado soma a empresa e as controladas; individual é só a empresa-mãe.

Receita líquida. Vendas do ano já descontados impostos e devoluções.

Margem EBIT. Resultado da operação antes de juros e impostos, dividido pela receita.

Margem líquida. Lucro do período dividido pela receita.

Endividamento. Parte do ativo financiada por terceiros: 1 – patrimônio líquido ÷ ativo total.

Percentil. Posição numa fila de 0 a 100. Percentil 30: 30% do grupo está abaixo.

K-means. Algoritmo que separa as empresas em k grupos de perfil parecido.

Padronizar. Pôr as variáveis na mesma escala para nenhuma dominar a distância.

Silhueta. Nota de −1 a 1 de quão bem separados estão os grupos; ajuda a escolher k.

Vizinhos mais próximos. As empresas com menor distância no espaço padronizado.

LLM. Modelo de linguagem que escreve texto a partir de uma instrução.

API. Endereço pelo qual o programa manda a instrução ao modelo e recebe a resposta.

Token. Pedaço de palavra; a API cobra por milhão de tokens.

Saída estruturada. O modelo responde em campos fixos que o programa lê sem adivinhar.

Marcador. Texto como `{margem_ebit}` que o código troca pelo número real.

Validador. Código que rejeita o texto que quebra as regras.

LangChain. Biblioteca que liga instrução, modelo e saída estruturada numa chain.

Streamlit. Biblioteca que cria a tela web em Python.

Docker. Empacota o programa e as dependências para rodar igual em qualquer máquina.

Terraform. Arquivo que descreve a infraestrutura; `apply` cria, `destroy` apaga.

Volume. Pasta que sobrevive quando o contêiner é recriado.

BPMN 2.0. Notação padrão para desenhar processos com raias, tarefas e decisões.

Camada gratuita. Uso da API sem custo, com limite de pedidos.

20 MINUTOS, DIVISÃO DO GUIA

Quem fala em cada parte

A Náthally monta o deck e abre e fecha a história de valor. Cada um manda a ela o conteúdo da parte que vai falar até qui 12/11. Todos falam, porque a banca avalia a divisão de participação.

00:00–03:00	03:00–06:00	06:00–12:00	12:00–16:00	16:00–18:00	18:00–20:00
Contexto e problema	**BPMN e arquitetura**	**Demo ao vivo**	**Detalhamento técnico**	**Governança, métricas e retorno**	**Conclusão**
Náthally	Marcos	Miguel	Eduardo	Náthally	Marcos
Persona, dor, tempo manual medido, pitch	Processo, fonte CVM, os seis passos	3 empresas de setores diferentes; vídeo backup pronto	Limpeza, K-means, regra de ouro do LLM, Terraform; por que não RAG nem fine-tuning no núcleo	Números medidos, custo, limites, privacidade	Lições, próximos passos, abertura à banca

PARA TODOS, EM PALAVRAS SIMPLES

Resumo final

O Raio-X pega números públicos de empresas, organiza, compara com empresas parecidas e transforma isso em conversa de vendas.

Marcos · Dados

Aprende: Pandas para limpar CSV, SQL básico e o que são DRE e balanço.

Faz: baixa os números da CVM, limpa e calcula 6 indicadores para cada empresa.

Entrega: a tabela de indicadores para o Eduardo e a busca de empresas para o Miguel.

Eduardo · IA e gestão

Aprende: K-means, vizinhos mais próximos e chamada ao Gemini com saída estruturada.

Faz: agrupa empresas parecidas e faz o LLM escrever o raio-x sem escrever números. Confere as entregas de cada sexta.

Entrega: o raio-x pronto para o Miguel mostrar e os resultados para a Náthally medir.

Náthally · Produto e métricas

Miguel · Tela e infraestrutura